Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

GenPO：生成式扩散模型与基于策略的强化学习的结合

丁树桐[1,5,*] 胡可[1,*] 钟山[2] 罗浩阳[1] 张维南[3] 王静雅[1,5] 王军[4] 叶石[1,5,†]

[1] 上海科技大学 [2] 中国电子科技大学
[3] 上海交通大学 [4] 伦敦大学学院
([5]) 教育部智能感知与人机协作重点实验室

{dingsht, huke2024, luohy12024}@shanghaitech.edu.cn 202211040927@std.uestc.edu.cn
wnzhang@sjtu.edu.cn
jun.wang@cs.ucl.ac.uk
{wangjingya, shiye}@shanghaitech.edu.cn

arXiv:2505.18763v4 [cs.LG] 2026年1月22日

摘要

强化学习（RL）领域的最新进展表明，基于生成扩散的策略具有强大的探索能力和多模态特性。尽管在离线强化学习和离策略强化学习场景中已取得显著进展，但将扩散策略整合到PPO等在线策略框架中的研究仍显不足。 鉴于IsaacLab等大规模并行GPU加速模拟器的广泛应用，这一缺口尤为显著。这些模拟器针对在线强化学习算法进行了优化，并能实现复杂机器人任务的快速训练。 一个关键挑战在于计算扩散策略下的状态-动作对数似然，这对高斯策略而言较为简单，但对于基于流的模型则难以处理，原因在于不可逆的前向-反向过程以及离散化误差（例如欧拉-丸山近似）。为弥合这一差距，我们提出 GenPO，这是一个生成式策略优化框架，利用精确的扩散逆演算来构建可逆的动作映射。 GenPO 引入了一种创新的双重虚拟动作机制，通过交替更新实现可逆性，从而解决了对数似然计算的障碍。此外，我们还利用动作对数似然进行无偏熵和 KL 散度估计，从而在策略内更新中实现了 KL 自适应学习率和熵正则化。 在八个IsaacLab基准任务（包括腿足行走（Ant、Humanoid、Anymal-D、Unitree H1、Go2）、灵巧操作（Shadow Hand）、空中控制（Quad-copter）和机械臂任务（Franka））上的广泛实验表明，GenPO优于现有的强化学习基线方法。 值得注意的是，GenPO是首个成功将扩散策略集成到基于策略的强化学习中的方法，从而释放了其在大型并行训练和真实世界机器人部署中的潜力。 GenPO 的官方实现代码可在 https://github.com/wadx2019/genpo/ 获取。

1 引言

近年来，生成式扩散模型（如 DDPM [25]、DDIM [52] 和流匹配 [36, 35]）因以下原因而引起了强化学习研究者的广泛关注

* 共同第一作者。†通讯作者。

第39届神经信息处理系统会议（NeurIPS 2025）。

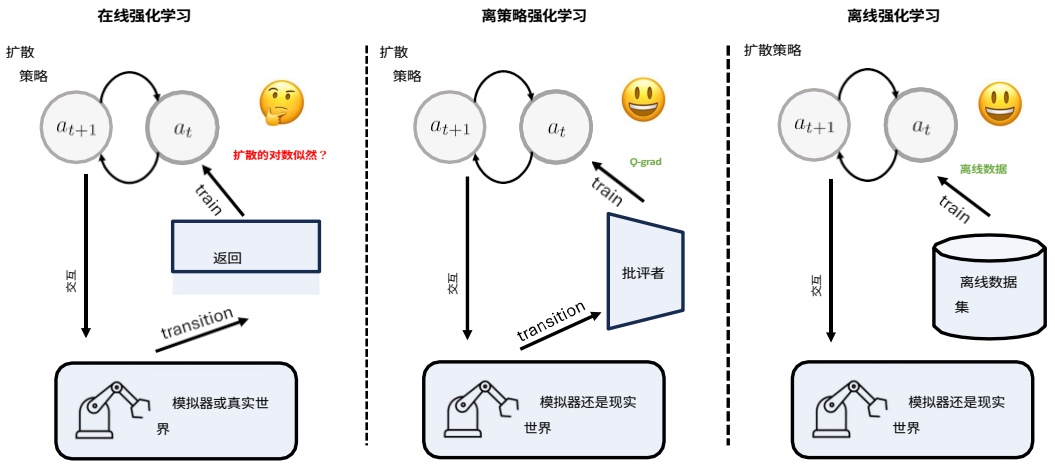

图1：现有的基于扩散的强化学习算法主要关注离策略（中间）和离线（右侧）强化学习。这是因为在离策略强化学习中，我们通常可以获得Q函数的梯度来更新扩散策略；而在离线强化学习中，我们可以利用离线数据来训练智能体。 然而，对于基于扩散的在策略（左）强化学习算法而言，目前仍面临一个挑战，即无法获得扩散的对数似然。

相比于传统的参数化高斯策略，它们具有强大的探索能力和多模态特性。然而，该领域现有的研究几乎仅关注离线强化学习[60, 1, 27, 7, 8, 24, 67, 40]和离策略强化学习[62, 13, 43, 41, 59]方法，而将扩散或流式策略融入PPO[51]等在线强化学习中的研究仍处于探索初期。 然而，现有的大规模并行GPU加速模拟器，如Isaac Gym [38]及其后续版本IsaacLab [32]，主要适用于策略内强化学习算法的训练，尤其是PPO，这些算法能够在相对较短的实际运行时间内取得显著的性能表现。 这导致了一个根本性的困境，阻碍了现有扩散/流式强化学习算法在现实应用中的实际部署 [10, 31, 42, 45, 14]。

与应用于离策略强化学习（off-policy RL）的扩散模型[13]不同，将流策略与在策略强化学习相结合的主要挑战在于如何计算状态-动作对的对数似然，而对于高斯策略而言，这却十分简单。 其根本原因在于生成式扩散策略的前向和反向过程之间存在不一致性和不可逆性，这是由欧拉-丸山（EM）离散化[48, 5]引起的。尽管如此，基于策略的强化学习中的优化目标仍需要给定状态-动作对的概率密度。 在此背景下，在流模型或扩散模型中估计给定状态-动作对的概率密度并非易事，而在基于策略的强化学习范式中进一步利用该估计值来改进扩散或流策略，则面临着额外的挑战。

为应对这些挑战，我们受精确扩散逆问题[57]的启发，提出了GenPO。该方法通过构建可逆的流映射，从而避免了扩散策略中正向过程与反向过程之间的不匹配。 具体而言，由于精确扩散逆向推导的限制，我们在 GenPO 中首先构建了一个动作空间大小为原始两倍的新马尔可夫过程，然后通过交替更新虚拟动作的两部分来实现可逆流过程。在此情况下，我们可以借助类似归一化流 [46, 15] 的变量变换理论，计算该新马尔可夫决策问题中给定动作的精确概率密度。 此外，在推理阶段，虚拟动作的两部分将被平均为一个整体，并映射回原始动作空间。因此，我们可以在重新构建的马尔科夫决策问题中执行GenPO来更新生成式扩散策略，但最终仍能获得原始任务的最优解。

此外，利用精确的概率密度，我们估算了扩散策略的熵以及相对于行为扩散策略的库尔巴克-莱布勒（KL）散度[11]。 这使得熵正则化与KL自适应学习率调整能够结合到GenPO中，而这种结合在PPO中已被证实是有效的。为了验证GenPO的优越性，我们在8个IsaacLab基准测试[38]上进行了实验，这些测试涵盖了机器人蚂蚁、类人机器人、四旋翼飞行器、Franka

机械臂 [23]、Shadow灵巧手 [56]、ANYbotics anymal-D 以及 Unitree 腿式机器人 [68]。 最终结果表明，所提出的GenPO在累积回报方面优于先前的强化学习基线模型，同时保持了相当的样本效率并实现了更快的收敛速度。值得注意的是，GenPO是首个将生成式扩散策略融入基于策略的强化学习算法的尝试，为扩散型策略在大型并行模拟器和真实世界机器人控制中的应用开辟了全新的途径。我们的贡献总结如下：

- **架起生成式扩散模型与在策略强化**学习**之间的桥梁。**GenPO 首次实现了基于扩散的策略与在策略强化学习的稳定集成，成功地在大型 GPU 并行模拟器（IsaacLab）中部署了扩散模型固有的探索能力和多模态特性。
- **弥合扩散策略中的似然差距。**与具有闭式密度的高斯策略不同，扩散策略缺乏可处理的似然函数。GenPO通过采用可逆的扩散动力学克服了这一问题，从而实现了：1) 精确的对数似然计算；2) 无偏的熵估计；3) 解析的KL散度——从而为表现力强的扩散模型带来了高斯模型式的优势。
- **在 IsaacLab 基准数据集上的全面实验。**我们在 IsaacLab 基准数据集上对 GenPO 进行了评估。实验结果表明，在大规模并行环境中，先前的基于扩散的强化学习算法几乎无效，而 GenPO 在样本利用效率和单次奖励方面表现最佳，远超其他算法。

2 相关工作

在本节中，我们将回顾用于策略学习的生成模型（如VAE [28]、GAN [12]、归一化流 [46]、扩散模型 [65] 以及基于流的模型 [36, 34]）的相关文献，并根据其学习范式将其大致分为两类。

在线强化学习的生成式策略。在线强化学习[54]的目标是在与给定环境的交互中学习出最优策略。由于缺乏动作标签，在在线强化学习范式下训练生成式模型策略具有一定挑战性。在线强化学习中的生成式策略学习方法大致可分为两种范式。 第一类范式将生成式策略视为类似神经网络的黑箱函数逼近，并通过策略梯度对其进行优化。该范式下的代表性方法包括 DACER [59]、CPQL [9]、FlowPG [4]、SAC-NF [39] 和 TRPO-NF [55]，它们直接对生成式模型策略应用确定性策略或策略梯度。 相比之下，第二类方法利用生成模型自身的内部结构和机制来实现策略优化。例如，DIPO [62] 和 QVPO [13] 分别利用 Q 函数的梯度和价值幅度来识别最优动作，随后将这些动作应用于扩散模型的变分损失中。 此外，QSM [43] 和 MaxEntDP [16] 将扩散模型中的噪声网络视为目标策略分布的评分函数，进而利用 Q 函数及其变体的梯度来训练噪声网络。 至于基于归一化流的方法，MEow [6] 利用流网络的分层非线性特性来训练 Q 函数和 V 函数，从而基于 SAC [21, 22] 生成相应的最大熵归一化流策略。 总体而言，当前在线强化学习中采用生成模型策略的方法主要侧重于将这些模型与SAC等离策略强化学习算法相结合，而将其与在策略强化学习方法相结合的研究则寥寥无几。

适用于其他学习范式的生成策略。与在线强化学习的生成策略相比，现有关于生成策略的研究更多地集中在离线强化学习[30]和模仿学习范式上，在这些范式中，策略是通过离线数据集学习而来的，无需与环境交互。 在离线强化学习领域，BCQ [18]、PLAS [66] 和 SPOT [61] 采用了 VAE [28] 策略正则化器，以防止策略在数据集支持集之外进行优化。此外，CPED [64] 利用流 GAN [20] 实现了更精确的策略正则化。此外，diffusion-QL [60]、EDP [27]、SRDP [1]、CEP [37] 和 FQL [41] 利用扩散 [25] 和流 [36, 34] 策略来精确建模离线数据集中的策略分布，从而获得具有更强泛化能力的策略。 在模仿学习方面，diffusion policy [10] 和 diffuser [26] 分别作为利用扩散模型拟合状态-动作映射和状态-轨迹映射的典型范例。后者也被称为扩散规划器。随后，FMIL [47]、AVDC [29] 和 decision diffuser [2] 沿袭了这一思路，并展示了增强的

在不同机器人上的表现。此外，DPPO [44] 应用策略梯度来微调使用离线数据集训练的扩散策略。尽管如此，DPPO 仅探索了在微调离线预训练的扩散策略时使用强化学习技术，而非提出一种基于扩散的在线强化学习算法。

然而，上述所有生成式策略学习方法均未能与在线强化学习算法有效集成，导致其无法充分利用现代大规模并行GPU加速仿真器。具体而言，离线策略算法在此类仿真器中往往难以收敛，而离线强化学习和模仿学习方法则因缺乏在线交互而与之根本不兼容。相比之下，我们提出的生成式扩散策略优化（GenPO）能够与在策略强化学习算法无缝集成，从而利用大规模GPU并行化模拟平台，在较短的实际运行时间内高效训练出高性能的生成式策略。

3 前言

3.1 基于策略的强化学习

强化学习问题[54]被形式化为马尔可夫决策过程（MDP），由元组 $(S, A, p, r, \rho_0, \gamma)$ 定义，其中 S 是状态空间，A 是动作空间，$p(s' \mid s, a) : S \times A \times S \to [0, \infty)$ 表示状态*转移动力学*，$r(s, a) : S \times A \to R$ 是奖励，$\rho_0(s) : S \to [0, \infty)$ 是初始状态的分布，而 $\gamma \in [0, 1)$ 是价值估算的贴现因子。强化学习的目标是最大化预期折现回报，即 $J(\vartheta) = E_{\tau \sim \pi_\theta}\left[\sum_{t=0}^{\infty} \gamma^t r_t\right]$，其中 $\pi_\theta(a \mid s)$ 是由 ϑ 参数化代理的行为，且这会在行为轨迹 τ 上诱导出相应的分布。为方便起见，强化学习还定义了两个不同的价值函数：状态价值函数 $V_\pi(s) = E_{\tau \sim \pi}\left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s\right]$ 以及状态-动作价值函数 $Q_\pi(s, a) = E_{\tau \sim \pi}\left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s, a_0 = a\right]$。此外，其优点效用函数，它表示在给定状态下采取某特定行动相对于预期回报所获得的收益，定义为 $A_\pi(s, a) = Q_\pi(s, a) - V_\pi(s)$。

在策略内强化学习算法利用当前策略自身生成的状态转移来训练策略，而在策略外强化学习算法则使用来自其他策略的状态转移作为训练样本。虽然在策略内强化学习算法能够保持行为策略与目标策略之间的一致性，但往往存在方差大、样本效率低的问题。近似策略优化（PPO）[51] 通过引入截断替代目标函数来解决这些挑战：

$$L^{CLIP}(\vartheta) := E_{(s,a)\sim\pi_{\theta_{old}}}\left[\min\left(r_t(\vartheta)\hat{A}_t,\ \mathrm{clip}(r_t(\vartheta), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right], \tag{1}$$

其中 $r(\vartheta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$，且 $\hat{A}_t$ 是通过 GAE [50] 估计的优势函数。由通过利用重要性采样技术和信任域的见解[49]，且无需二阶复杂度来近似KL散度约束，PPO能够实现稳定且高效的策略更新。PPO的简单性、鲁棒性以及在连续控制基准测试[38, 68]上的强劲实证表现，使其成为许多领域中首个被采用的算法。

3.2 生成式扩散模型与流匹配

生成式扩散模型[25, 53, 52]是一种强大的隐变量生成模型，它能够通过基于噪声网络的去噪过程，将来自标准高斯分布 $x_T \sim N(0, I)$ 的样本转换为数据分布 $x_0 \sim p_{data}$。x_0 与 x_T 之间的关系由扩散的正向随机微分方程（SDE）定义

$$dx_t = f(x_t, t)\,dt + g(t)\,dW_t, \tag{2}$$

其中 W_t是标准维纳过程（又称布朗运动），$f(x_t, t)$ 是一个向量值函数，称为 x_t的漂移系数，而 $g(t)$ 是一个标量函数，称为 x_t的扩散系数。根据[53]，扩散的逆时间随机微分方程（即去噪过程）为

$$d\bar{x}_t = f(x_t, t) - g(t)^2 \nabla_x \log p_t(x_t)\,dt + g(t)\,d\bar{W}_t, \tag{3}$$

其中 $\bar{W}_t$是当时间从 T 向 0 倒流时的标准维纳过程。 实际上，DDPM [25] 将该随机微分方程离散化，并将前向步近似为 $q(x_t \mid x_{t-1}) :=$

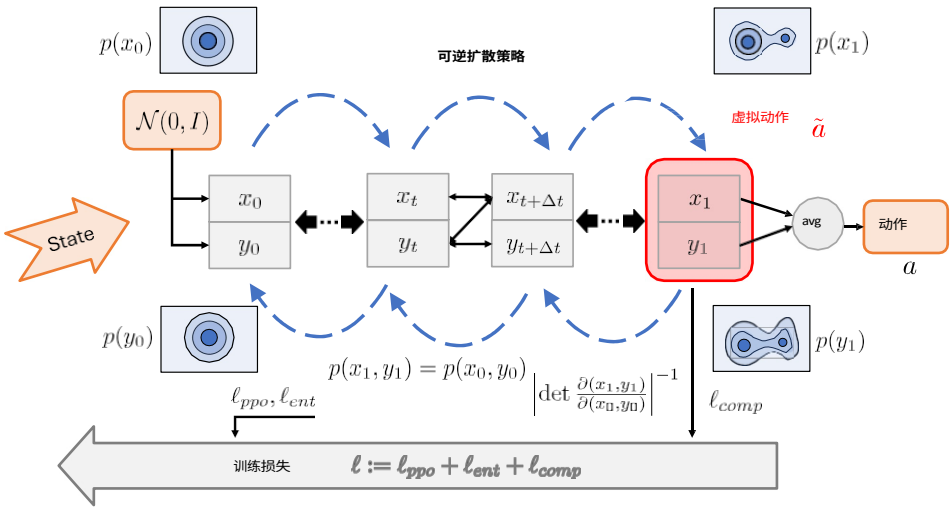

图2：GenPO的正向和反向过程。正向过程是根据给定状态采样动作；反向过程是计算给定状态-动作对的概率密度。值得注意的是，正向和反向过程是可逆的。

$(x_t; \sqrt{1-\beta_t}\, x_{t-1}, \beta_t I)$，其中 β_t 为方差调度。DDPM中的噪声网络 $\epsilon_\theta(x_t, t)$ 可通过变分下界损失进行训练：

$$\mathbb{E}_{t\sim[1,T], x_0, \epsilon_t} \left\| \epsilon_t - \epsilon_\theta\left(\sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon_t, t\right) \right\|^2, \tag{4}$$

其中 $\alpha_t = 1 - \beta_t$，$\bar{\alpha}_t = \prod_{s=0}^{t} \alpha_s$，且 $\epsilon_t \sim \mathrm{N}(0, I)$。

与经典扩散模型相比，流匹配模型 [36, 34] 旨在实现更快的生成

DDPM 等模型，可视为生成式扩散模型的一种特殊类型 [19]。与

与DDPM类似，流匹配模型学习一个随时间变化的向量场 $v_\theta(x, t)$，即DDPM中的噪声网络，该向量场将样本沿预定义的条件分布族 $\{p_t\}_{t\in[0,1]}$ 进行传输

满足 $x_1 \approx p_{\text{data}}$ 且 $x_0 \approx \mathrm{N}(0, I)$。因此，目标分布 p_{data} 的样本可通过

通过求解常微分方程 $x = x + \int_0^1 v(x, t)dt$ 来获得。

此外，流量匹配的损失定义为 $L(\vartheta) = \int_0^1 \mathbb{E}_{x\sim p_t} \left\| v_\theta(x, t) - v^*(x, t) \right\|^2 dt$，其中

$v^*(x_t, t)$ 是所选路径下的真实速度场。当路径为高斯扩散时，$v^*(x, t)$ 恰与扩散中逆向 SDE 的评分漂移项一致。然而，

在生成式扩散框架中无法直接计算。

4 GenPO：一种基于扩散模型的在策略强化学习方法

如第3.2节所述，在生成模型中无法直接计算给定样本的对数似然。然而，为了将扩散策略整合到正则强化学习中，我们必须给出在给定状态-动作对下用于策略更新的对数似然显式公式。因此，我们首先阐明导致扩散模型中对数似然计算困难的内在原因。 随后，我们通过以下方式应对这些挑战：(1) 应用精确的扩散逆向技术[57]，并利用类似归一化流[46]的变量变换技术；(2) 构建一个具有修改后动作空间的重新表述的马尔可夫决策过程，并采用一种将生成的动作映射回原始动作空间的技巧。

此外，基于该框架，我们还提出了一种无偏估计方法，用于估计扩散策略的熵以及不同生成式扩散策略之间的库尔巴克-莱布勒（KL）散度。值得注意的是，此前基于扩散的强化学习方法尚未实现这一点。 此外，由于策略更新实际上是在重新构造的马尔科夫决策过程（MDP）上进行的，这会诱发多余的探索行为，从而降低强化学习的效率。为解决这一问题，我们还引入了一个辅助的压缩损失项。借助这些技术，我们最终展示了所提GenPO算法的实际实现，该算法成功且有效地将生成策略融入了PPO [51] 中。图2展示了所提GenPO的训练和推理过程。

4.1 计算扩散概率的挑战

回顾现有的生成模型，如VAE [28]、GAN [12]、归一化流 [46] 和扩散模型 [53]，可以发现只有归一化流及其变体（如流式GAN [20]）能够通过变量变换定理 [46] 进行精确的似然计算。 相比之下，对于其他生成模型，概率密度或相关统计量只能通过特殊设计 [13, 5, 59] 进行近似获取。在正则强化学习算法中，将此类近似概率密度估计应用于策略更新是不可接受的。

根据引理 1，若要精确计算生成模型的概率密度，该生成模型必须在采样分布（如标准高斯分布）与目标分布之间具有可逆性。因此，我们考虑设计一个可逆的生成扩散模型，并利用变量变换定理 (5) 来计算其概率密度。

引理 1. ***（变量替换 [3]）*** *设 $f : \mathbb{R}^n \to \mathbb{R}^n$ 是一个可逆且光滑的映射。若随机变量 X 服从分布 $q(x)$，且随机变量 $Y = f(X)$ 经函数 f 变换，则 Y 的分布 $p(y)$ 为*

$$p(y) = q(x) \det \left(\frac{\partial f}{\partial x} \right)^{-1} \tag{5}$$

然而，正如[57, 58, 63]中所提到的，实现一个精确可逆的扩散模型并非易事。这是由于生成式扩散模型的前向过程与反向过程之间存在不一致性。式(6)展示了DDIM[52]的前向和反向过程。可以观察到
这种不一致源于正向过程中用 x_{t-1} 近似 x_t，因为
x_t在前向步骤 $t-1$ 中不可用。

$$\text{反面：} \quad x_{t-1} = \sqrt{\alpha_{t-1}} \frac{x_t - \sqrt{1-\alpha_t}\,\epsilon_\theta(x_t, t)}{\sqrt{\alpha_t}} + \sqrt{1-\alpha_{t-1}}\,\epsilon_\theta(x_t, t)$$

$$\text{正向：} \quad (x) = \frac{x_{t-1} - b_t \epsilon_\theta(x_t, t)}{a_t} \approx \frac{x_{t-1} - b_t \epsilon_\theta(x_{t-1}, t)}{a_t} \tag{6}$$

其中 $a_t = \sqrt{\alpha_{t-1}/\alpha_t}$，$b_t = -\sqrt{\alpha_{t-1}(1-\alpha_t)/\alpha_t} + \sqrt{1-\alpha_t}$。

4.2 在重新表述的马尔科夫决策过程（MDP）中的精确扩散反演

因此，要实现可逆扩散模型，必须解决这一问题。受EDICT[57]的启发，我们通过维护两个耦合噪声向量，并在生成式扩散模型的前向和反向过程中交替更新它们，从而实现了可逆扩散模型，并将其扩展为流匹配[35, 36]以实现快速生成，如式(7)和(8)所示。 然而，这两个耦合噪声向量也导致了样本空间的倍增。这意味着当动作空间的维度为奇数时，我们无法直接将该技术应用于扩散策略。

为了解决这个问题，我们在GenPO中将原始的MDP问题重新表述为具有双倍虚拟动作空间˜的问题。 每个虚拟动作 $\tilde{a} = (x, y)$ 由两个分量组成，随后对其求平均值，从而在原始空间中生成单个动作 $a = \frac{x+y}{2}$。显然，当重新表述的MDP中的策略为最优时，它在原始MDP问题中的平均映射下也是最优的。

$$\text{反向：} \quad \tilde{x}_{t+\Delta t} = x_t + v_\theta(y_t, t)\Delta t, \qquad \tilde{y}_{t+\Delta t} = y_t + v_\theta(\tilde{x}_{t+\Delta t}, t)\Delta t \tag{7}$$

$$\text{混合：} \quad x_{t+\Delta t} = p \cdot \tilde{x}_{t+\Delta t} + (1-p) \cdot \tilde{y}_{t+\Delta t}, \quad y_{t+\Delta t} = p \cdot \tilde{y}_{t+\Delta t} + (1-p) \cdot x_{t+\Delta t}$$

值得注意的是，与仅采用精确扩散反演来推断扩散过程的EDICT不同，GenPO会*为x_0和y_0*独立采样标准高斯噪声，而非仅采样一个*噪声ϵ*并将$x_0 = y_0 = \epsilon$，从而能够通过变量变换进行概率计算。
(5). 此外，由于修改后的马尔科夫决策过程（MDP）中的动作空间翻倍，扩散策略中存在一个无意义的探索问题。例如，如果最优动作 $a^* = 0$，则 $\tilde{a} = (1, 1)$ 和 $(2, 2)$ 都是最优的虚拟动作。 因此，为避免在修改后的马尔科夫决策过程（MDP）中进行不必要的探索，采用了混合方案（7, 8），以确保虚拟动作的两个组成部分 *x 和 y* 保持紧密对齐。在（7, 8）中，该混合方案用于促进 $\tilde{a}$ 的 x 和 y 组件之间的信息交换，从而确保扩散策略收敛至

x和y部分之间偏差最小的虚拟操作。这里使用系数p来控制交换信息的强度。

$$\text{解混：}\quad \tilde{y}_{t+\Delta t} = \frac{y_{t+\Delta t} - (1-p)\, x_{t+\Delta t}}{p} \qquad \tilde{x}_{t+\Delta t} = \frac{x_{t+\Delta t} - (1-p)\, y_{t+\Delta t}}{p} \tag{8}$$

$$\text{正向：}\quad y_t = \tilde{y}_{t+\Delta t} - v_\theta(\tilde{x}_{t+\Delta t}, t)\Delta t,\ x_t = \tilde{x}_{t+\Delta t} - v_\theta(y_t, t)\Delta t$$

4.3 实际实现

为了增强 GenPO 的探索能力并稳定训练过程，我们估算了策略熵，并为流策略引入了基于自适应 KL 散度的学习率调度方案。与高斯策略不同，流策略的熵和 KL 散度没有闭式表达式，因此无法直接计算。因此，先前的扩散强化学习算法 [13, 59, 5] 一直依赖于启发式近似来促进探索。 相比之下，GenPO具有精确可逆性（第4.2节），可通过第4.1节中的变量变换(5)精确计算任意状态-动作对的对数似然。这使得熵和KL散度的估计均无偏。据此，我们在式(9)中定义了熵损失。

$$L^{ENT}(\pi_\theta) := \mathbb{E}_{s,\tilde{a}\sim\pi_\theta}[\log(\pi_\theta(\tilde{a}\mid s))]。 \tag{9}$$

此外，为了实现学习率的自适应调度，我们还给出了KL散度的无偏估计（如算法1所示），计算扩散策略之间KL散度的估计公式为

$$KL(\pi_{\theta_{old}} \mid \pi_\theta) := \mathbb{E}_{s,\tilde{a}\sim\pi_{\theta_{old}}}[\log(\pi_{\theta_{old}}(\tilde{a}\mid s)) - \log(\pi_\theta(\tilde{a}\mid s))]. \tag{10}$$

我们还展示了该算法在 PPO 框架中的具体实现。PPO 的替代损失函数修改为 (11)。

$$L^{PPO}(\vartheta) := \mathbb{E}_{(s_t,\tilde{a}_t)\sim\pi_{\theta_{old}}} \min\left(\frac{\pi_\theta(\tilde{a}_t\mid s_t)}{\pi_{\theta_{old}}(\tilde{a}_t\mid s_t)}\hat{A}_t,\ \mathrm{clip}\left(\frac{\pi_\theta(\tilde{a}_t\mid s_t)}{\pi_{\theta_{old}}(\tilde{a}_t\mid s_t)},\ 1-\epsilon,\ 1+\epsilon\right)\hat{A}_t\right)。 \tag{11}$$

值得注意的是，为缓解这一问题并防止对动作空间进行无效探索，我们引入了一个压缩损耗定义为 $\mathbb{E}_{x,y\sim\pi_\theta}\left[(x_1 - y_1)^2\right]$，这会减小 x 与 y分量，在策略损失中。最终的扩散策略损失如式(12)所示。

$$L(\vartheta) := L^{PPO} + \lambda L^{ENT} + v\,\mathbb{E}_{x,y\sim\pi_\theta}\left[(x_1 - y_1)^2\right], \tag{12}$$

其中 λ 和 v 分别是熵和压缩损耗的系数。

5 实验

在本节中，我们针对IsaacLab中的若干控制任务对所提方法进行了实证评估。此外，我们还开展了消融研究以探究关键超参数的影响。这些实验旨在将我们的方法与流行的在线强化学习算法进行比较，并分析超参数选择如何影响性能。

5.1 比较评估

设置。为了评估我们的方法，我们在IsaacLab提供的一系列基准任务上进行了实验。本研究中使用的基准环境包括Isaac-Ant-v0、Isaac-Humanoid-v0、Isaac-Lift-Cube-Franka-v0、 Isaac-Repose-Cube-Shadow-Direct-v0、Isaac-Velocity-Flat-Anymal-D-v0、Isaac-Velocity-Rough-Unitree-Go2-v0、Isaac-Velocity-Rough-H1-v0 以及 Isaac-Quadcopter-Direct-v0。 为简洁起见，本文余下部分将分别将这些环境简称为 **Ant**、**Humanoid**、**Franka Arm**、**Shadow Hand**、**Anymal-D**、**Unitree-Go2**、**Unitree-H1** 和 **Quadcopter**。 我们将 GenPO 算法与若干知名的无模型算法（包括 DDPG、TD3、SAC、PPO）以及两种基于扩散的离策略算法（DACER 和 QVPO）进行了对比与评估。为评估统计稳健性，所有实验均在五个随机种子下重复进行。有关实验的更多细节可参见补充材料。

图3展示了平均单次回报（实线）及其一个标准差（阴影区域）。与

算法1 生成式扩散策略优化

输入： 生成扩散策略 $\pi_\theta(\tilde{a} \mid s)$，价值网络 $V_\omega(s)$。

$\vartheta' \leftarrow \vartheta$

for t **in** $1, 2, \ldots, T$ **时**

  对于每个演员，**执行**

    从π_θ中采样虚拟动作$\tilde{a} = (x, y)$ $(a \mid s)$

    使用 $a = \frac{x+y}{2}$ 与环境交互 N 个时间步

    计算已执行虚拟动作 $\pi_\theta(\tilde{a} \mid s)$ 的概率

    使用GAE估计优势$\hat{A}_1, \ldots, \hat{A}_N$并返回$\hat{R}_1, \ldots, \hat{R}_n$

    在回溯过程中存储状态转换、虚拟动作、概率和优势值

  结束 for

  for k **in** $1, 2, \ldots, K$ **循环**

    根据 (10) 式估计 KL 散度，并调整学习率 α

$$\alpha \leftarrow \begin{cases} \frac{\alpha}{2}, & D_{KL} \geq \epsilon, \\ 2\alpha, & D_{KL} \leq \epsilon. \end{cases}$$

    使用来自rollout的第n个微批次，通过代理损失(12)更新$\pi_\theta(\tilde{a} \mid s)$

    更新价值网络 V_ω (s) 时，损失为 $\mathbb{E}_{s,a\sim\pi_\theta} \left\| \psi(s) - \hat{R}(s, a) \right\|^2$

  结束

结束 for

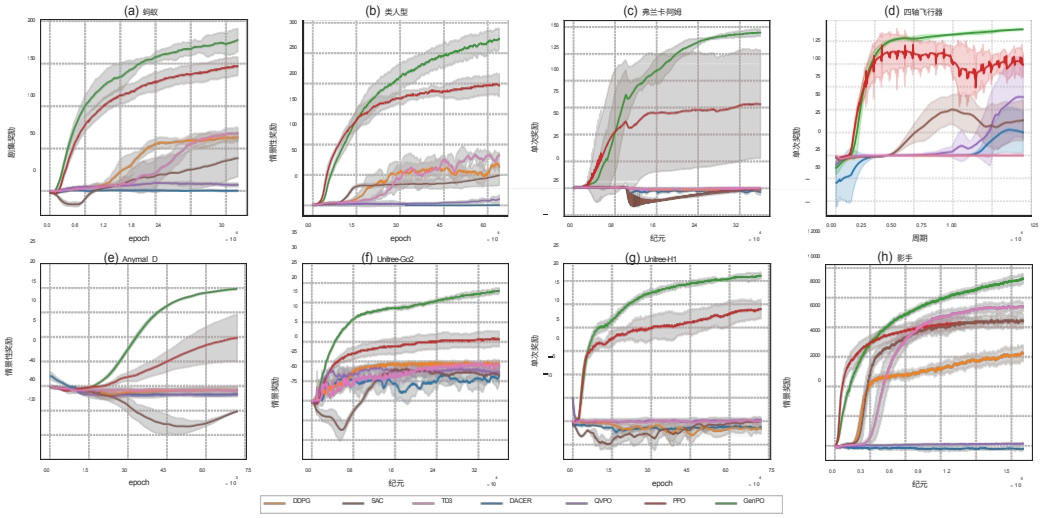

图3：IsaacLab 8个 基准测试的学习曲线。结果为5次运行的平均值。x轴表示训练 epoch 数，y轴显示平均单集回报，阴影部分表示一个标准差。

离策略基线，得益于同步数据采集，这提高了训练的稳定性和收敛速度。 相比之下，离策略方法在大规模并行设置中表现欠佳。这一问题在基于扩散的算法中尤为突出，其策略难以追踪重放缓冲区中快速变化的数据分布。此外，GenPO的生成式扩散策略相较于标准高斯策略能增强探索能力，从而促进更高效且稳健的策略优化。这些因素共同解释了GenPO在多样化任务中表现优异的原因。

表 1 报告了八项基准任务的平均回合回报（含标准差）。GenPO 在所有环境中均保持最高平均回报，显著优于所有算法。值得注意的是，在最具挑战性的任务中，例如 Unitree 机器人的运动

表 1：在 IsaacLab 基准测试中，GenPO 与几种主流强化学习方法的平均最终奖励对比。各任务的最大值以粗体显示。五次运行的标准差用括号标出。

算法	Ant	人形机器人	Franka-Arm	四旋翼	AnymalD	Unitree-Go2	Unitree-H1	Shadow-Hand
DDPG [33]	62.96(5.18)	63.34(7.39)	-1.61(0.76)	0.03(0.13)	-0.86(0.55)	9.09(0.81)	-6.63(1.04)	6209.59(559.44)
TD3 [17]	67.80(7.05)	82.36(4.70)	0.03(0.12)	0.17(0.15)	-0.89(0.77)	8.44(1.05)	-4.97(0.87)	9386.64(314.37)
SAC [22]	38.68(21.84)	49.52(16.89)	-1.10(0.95)	38.46(22.20)	-5.12(0.14)	6.67(2.02)	-5.05(0.18)	8459.74(135.79)
DACER [59]	0.29(0.98)	0.58(0.01)	-3.43(2.82)	25.39(22.99)	-1.62(0.09)	6.37(2.07)	-6.21(0.17)	-207.43(88.82)
QVPO [13]	7.19(2.32)	10.59(6.30)	-0.12(0.14)	63.99(45.42)	-1.81(0.36)	7.34(0.62)	-4.72(0.16)	134.36(39.05)
PPO [51]	146.94(10.61)	197.25(18.26)	78.14(50.43)	99.08(13.49)	9.80(4.78)	15.67(1.92)	18.97(2.02)	8402.21(435.64)
GenPO(*)	**177.90(13.87)**	**273.94(16.96)**	**144.78(3.10)**	**137.95(0.84)**	**19.80(0.16)**	**28.01(0.76)**	**26.09(0.68)**	**11282.35(322.94)**

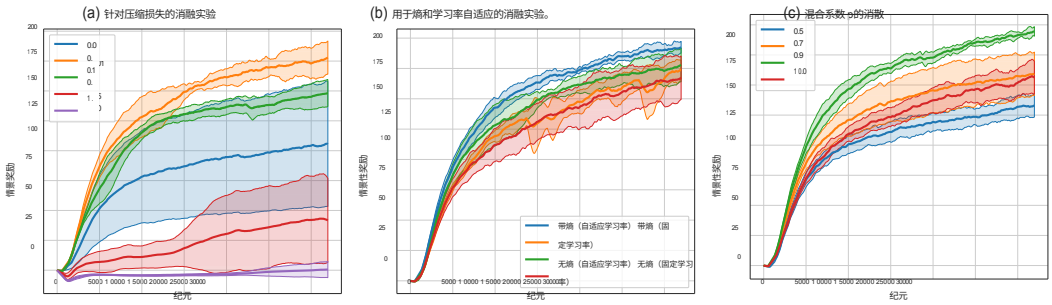

图4：消融研究结果。(a) 压缩损耗*系数v*的变化对训练稳定性和最终性能的影响。（）(b) 熵和学习率自适应对探索与收敛的影响。(c) 流策略中不同混合*系数ρ*下的性能表现。

在“影子手”操作任务中，GenPO不仅展现出更高的回报，还具有更低的方差，表明其训练稳定性更强。

5.2 消融研究

为了更好地理解GenPO中各组件的重要性，并解释其在IsaacLab基准测试中的优异表现，我们针对三个关键设计选择进行了消融研究：1) 训练目标中压缩损失的影响； 2) 熵与KL散度估计的影响；以及 3) 混合系数 ρ 的选择。我们以 Isaac-Ant-v0 任务的结果作为代表性示例，因为在其他环境中也观察到了类似的趋势。其他消融实验结果详见补充材料。

压缩损耗的影响。为了验证压缩损耗对最终性能的影响，我们调整公式(12)中的*系数*v，并分析图4(a)中得到的训练曲线。我们评估了v 0、0.01、0.1、0.5、1.0的值，*发现*v=0.01在稳定性和正则化之间提供了最佳平衡。 较大的值会过度约束策略，导致性能不佳；而排除该损失项（$v = 0$）则会减缓收敛速度。基于这种权衡，我们在所有实验中均将 v 设为 0.01。

熵与学习率自适应。图4(b)展示了熵正则化和学习率自适应的效果。学习率的自适应调整使得收敛更快且更稳定，而熵正则化则增强了探索能力并带来了更高的回报。实验结果证实，这两项组件（按第4.3节所述实现）显著提升了整体性能。 在所有任务中，我们采用自适应学习率方案，并在式(12)定义的损失函数中加入了熵正则化项。

混合系数。如图4(c)所示，当混合系数设置为 $\rho = 0.9$ 时，GenPO 表现最佳。这是因为如果 ρ 设置过低，会导致正向混合过程（8）在数值上不稳定，从而使该值过大并影响训练的稳定性。相反，如果 ρ 设置过高，会在翻倍的虚拟动作空间中引入冗余的探索，从而减缓收敛速度。因此，选择 $\rho = 0.9$ 可在稳定性和探索效率之间实现合理的平衡，故我们在所有实验中均将 ρ 设为 0.9。

6 结论、局限性与未来工作

本文提出了一种名为生成式扩散策略优化（GenPO）的新方法，该方法将生成式扩散策略整合到了基于策略的强化学习框架中。GenPO 能够在扩散模型中对动作进行可计算的对数似然计算——这是先前研究中无法实现的——并进一步无偏地估计扩散策略的熵和KL散度，从而在策略更新过程中实现熵正则化和自适应学习率调整。 最后，在八个IsaacLab基准测试中，GenPO相较于现有强化学习基线（包括基于扩散的强化学习方法）展现出更优异的性能，同时保持了相当的样本效率并实现了更快的收敛速度，这凸显了生成式扩散策略在基于策略的强化学习中，对于大规模仿真和真实世界机器人控制的巨大潜力。

尽管GenPO表现优异，但其计算和内存开销相对较高，这一问题亟待在未来解决。虽然GPU的并行性有助于缓解这一问题，但在计算雅可比行列式时，GenPO仍面临相当大的复杂度。因此，我们未来的工作将致力于探索如何优化GenPO的计算和内存效率，以促进其在更多实际应用中的部署。

致谢

本研究得到国家自然科学基金（62303319、 62406195）、上海市地方高校能力建设项目（23010503100）、上海科技大学AI4S计划（SHTAI4S202404）、上海科技大学HPC平台，以及教育部智能感知与人机协作重点实验室（上海科技大学）、上海市智能视觉与成像工程研究中心。 本研究还部分得到了Fcloud有限公司提供的计算资源支持。

参考文献

[1] Suzan Ece Ada, Erhan Oztop, and Emre Ugur. 离线强化学习中用于分布外泛化的扩散策略。*IEEE机器人与自动化通讯*，9(4):3116–3123，2024年4月。

[2] Anurag Ajay、Yilun Du、Abhi Gupta、Joshua Tenenbaum、Tommi Jaakkola 和 Pulkit Agrawal。条件生成模型是否足以满足决策需求? *arXiv 预印本 arXiv:2211*.15657，2022。

[3] 约瑟夫·K·布利茨斯坦和杰西卡·黄。*《概率导论》*。查普曼与霍尔/CRC出版社，2019年。

[4] 贾纳卡·布拉曼加、凌佳静和阿克沙特·库马尔。《FlowPG：基于归一化流的动作约束策略梯度》。*《神经信息处理系统进展》*，36:20118–20132，2023。

[5] 奥努尔·切利克、李泽楚、丹尼斯·布莱辛、李戈、丹尼尔·帕拉尼切克、扬·彼得斯、乔治亚·查尔瓦扎基和格哈德·诺伊曼。《Dime：基于扩散的最大熵强化学习》。*arXiv预印本 arXiv:2502*.02316，2025年。

[6] 赵晨浩、钱锋、孙伟芳、李成光、Simon See 和 李春义。基于能量规范流的最大熵强化学习。*arXiv 预印本 arXiv:2405.13*629，2024。

[7] 陈华宇、卢成、应成阳、苏航和朱俊。基于高保真生成行为建模的离线强化学习。*arXiv预印本 arXiv:2209*.14548，2022。

[8] 陈宇辉、李浩然和赵东斌。基于一致性策略的连续控制增强。*arXiv预印本 arXiv:2310*.06343，2023。

[9] 陈宇辉、李浩然和赵东斌。基于一致性策略的连续控制增强。*收录于第23届自主代理与多智能体系统国际会议论文集*，第335–344页，2024年。

[10] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. 扩散策略：基于动作扩散的视觉运动策略学习。*arXiv预印本 arXiv:2303.04137*, 2023.

[11] 托马斯·M·科弗。*《信息论基础》*。约翰·威利父子出版社，1999年。

[12] 安东尼娅·克雷斯韦尔、汤姆·怀特、文森特·杜穆兰、凯·阿鲁库马兰、比斯瓦·森古普塔和阿尼尔·A·巴拉特。《生成对抗网络：综述》。*《IEEE信号处理杂志》*，35(1):53–65，2018。

[13] 丁树桐、胡可、张振浩、任坎、张维南、于静怡、王静雅和石叶。基于Q加权变分策略优化的扩散式强化学习。*arXiv预印本 arXiv:2405*.16173，2024。

[14] 丁树桐、周一苗、胡可、姚曦、严俊驰、唐晓英和石叶。Diopt：用于约束优化的自监督扩散。*arXiv预印本 arXiv:2502.10330*，2025年。

[15] Laurent Dinh、Jascha Sohl-Dickstein 和 Samy Bengio。基于真实非线性规划的密度估计。*arXiv预印本 arXiv:1605.08803*，2016年。

[16] Xiaoyi Dong、Jian Cheng 和 Xi Sheryl Zhang。基于扩散策略的最大熵强化学习。*arXiv 预印本 arXiv:2502.11612*，2025。

[17] Scott Fujimoto、Herke Hoof 和 David Meger。解决演员-评论家方法中的函数逼近误差。载于*《国际机器学习会议》*，第 1587–1596 页。PMLR，2018。

[18] Scott Fujimoto、David Meger 和 Doina Precup。无需探索的离策略深度强化学习。收录于*《国际机器学习会议》*，第 2052–2062 页，2019 年。

[19] 高瑞琪、埃米尔·霍格博姆、乔纳森·希克、瓦伦丁·德·博尔托利、凯文·P·墨菲和蒂姆·萨利曼斯。《扩散与流匹配：一枚硬币的两面》。2024年。*网址 https://diffusionflow.github.io*，2024年。

[20] A Grover、M Dhar 和 S Ermon。Flow-GAN：生成模型中最大似然与对抗学习的结合。arXiv 预印本。*arXiv 预印本 arXiv:1705*.08868，2017。

[21] Tuomas Haarnoja、Aurick Zhou、Pieter Abbeel 和 Sergey Levine。《软演员-批评家：基于随机演员的离策略最大熵深度强化学习》。载于*《国际机器学习会议》*，第 1861–1870 页。PMLR，2018。

[22] Tuomas Haarnoja、Aurick Zhou、Kristian Hartikainen、George Tucker、Sehoon Ha、Jie Tan、Vikash Kumar、Henry Zhu、Abhishek Gupta、Pieter Abbeel 等。软演员-批评家算法及其应用。*arXiv预印本 arXiv:1812*.05905，2018年。

[23] 萨米·哈达丁。弗兰卡·埃米卡机器人：机器人研究中的标准平台。*《IEEE机器人与自动化杂志》*，2024年。

[24] Philippe Hansen-Estruch, Ilya Kostrikov, Michael Janner, Jakub Grudzien Kuba, 和 Sergey Levine. Idql：作为具有扩散策略的演员-批评方法的隐式Q学习。*arXiv预印本 arXiv:2304.10573*, 2023.

[25] 乔纳森·何、阿贾伊·贾因和皮特·阿比尔。去噪扩散概率模型。*《神经信息处理系统进展》*，33:6840–6851，2020。

[26] 迈克尔·詹纳、杜一伦、约书亚·B·特南鲍姆和谢尔盖·莱文。基于扩散的规划用于灵活行为合成。*arXiv预印本 arXiv:2205*.09991，2022。

[27] 康冰一、马晓、杜超、庞天宇和严水成。离线强化学习的高效扩散策略。*《神经信息处理系统进展》*，第36卷，2024年。

[28] Diederik P Kingma 和 Max Welling. 自编码变分贝叶斯. *arXiv 预印本 arXiv:1312.6114*, 2013.

[29] Ko Po-Chen、Mao Jiayuan、Du Yilun、Sun Shao-Hua 和 Tenenbaum Joshua B. 通过稠密对应关系从无动作视频中学习动作，2023。

[30] Sergey Levine、Aviral Kumar、George Tucker 和 Justin Fu. 离线强化学习：教程、综述及未解问题的展望。*arXiv 预印本 arXiv:2005*.01643，2020年。

[31] 李翔、Varun Belagali、尚景焕和Michael S Ryoo。Crossway Diffusion：通过自监督学习改进基于扩散的视动策略。*arXiv预印本 arXiv:2307*.01849，2023。

[32] 李泽楚、陈涛、洪张伟、阿努拉格·阿贾伊和普尔基特·阿格拉瓦尔。并行Q学习：在超大规模并行模拟下扩展离策略强化学习。收录于《*国际机器学习会议*》，第19440–19459页。PMLR，2023年。

[33] Timothy P Lillicrap、Jonathan J Hunt、Alexander Pritzel、Nicolas Heess、Tom Erez、Yuval Tassa、David Silver 和 Daan Wierstra。基于深度强化学习的连续控制。*arXiv 预印本 arXiv:1509*.02971，2015。

[34] 亚伦·利普曼、瑞奇·T·Q·陈、赫利·本-哈穆、马克西米利安·尼克尔和马特·勒。生成建模中的流匹配。*arXiv预印本 arXiv:2210.02747*，2022年。

[35] Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel 和 Matthew Le. 生成建模中的流匹配. 收录于*第十一届学习表征国际会议*, 2023.

[36] 刘兴超、龚成悦和刘强。畅通无阻：利用整流流学习生成和迁移数据。*arXiv预印本 arXiv:2209.03003*，2022。

[37] 卢成、陈华宇、陈建飞、苏航、李崇轩和朱军。离线强化学习中基于精确能量引导扩散采样的对比能量预测。收录于《*国际机器学习会议*》，第22825–22855页。PMLR，2023。

[38] 维克多·马科维丘克、卢卡什·瓦夫日尼亚克、郭云荣、米歇尔·卢、基尔·斯托里、迈尔斯·麦克林、大卫·霍勒、尼基塔·鲁丁、亚瑟·奥尔希尔、安库尔·汉达和加夫里埃尔·斯泰特。Isaac gym：用于机器人学习的高性能基于GPU的物理模拟，2021年。

[39] 博格丹·马佐雷、唐·唐、奥黛丽·杜兰、乔埃尔·皮诺和R·德文·赫尔姆。通过归一化流在离策略算法中利用探索。收录于*机器人学习会议*，第430–444页。PMLR，2020年。

[40] 倪飞、郝建业、穆瑶、袁一夫、郑岩、王斌和梁志轩。Metadiffuser：作为离线元强化学习条件规划器的扩散模型。收录于*《国际机器学习会议》*，第26087–26105页。PMLR，2023年。

[41] 朴世弘、李启阳和谢尔盖·莱文。流式Q学习。*arXiv预印本 arXiv:2502.02538*，2025年。

[42] Tim Pearce、Tabish Rashid、Anssi Kanervisto、Dave Bignell、Mingfei Sun、Raluca Georgescu、Sergio Valcarcel Macua、Shan Zheng Tan、Ida Momennejad、Katja Hofmann 和 Sam Devlin。利用扩散模型模仿人类行为，2023。

[43] Michael Psenka, Alejandro Escontrela, Pieter Abbeel, 和 Yi Ma. 通过 Q 分数匹配从奖励中学习扩散模型策略。*arXiv 预印本 arXiv:2312.11752*, 2023.

[44] Allen Z Ren、Justin Lidard、Lars L Ankile、Anthony Simeonov、Pulkit Agrawal、Anirudha Majumdar、Benjamin Burchfiel、Hongkai Dai 和 Max Simchowitz。扩散策略优化。*arXiv 预印本 arXiv:2409*.00588，2024。

[45] Moritz Reuss、Maximilian Li、Xiaogang Jia 和 Rudolf Lioutikov。基于分数的扩散策略实现目标约束的模仿学习。*arXiv 预印本 arXiv:2304.02532*，2023。

[46] 达尼洛·雷森德和沙基尔·穆罕默德。基于归一化流的变分推断。收录于《*国际机器学习会议*》，第1530–1538页。PMLR，2015年。

[47] 昆汀·鲁克塞尔、安德烈亚·法拉利、塞雷娜·伊瓦尔迪和让-巴蒂斯特·穆雷。用于多支撑操纵的流匹配模仿学习。收录于*2024年IEEE-RAS第23届人形机器人国际会议（Humanoids）*，第528–535页。IEEE，2024年。

[48] 西莫·萨尔卡和阿诺·索林。*《应用随机微分方程》*，第10卷。剑桥大学出版社，2019年。

[49] 约翰·舒尔曼、谢尔盖·莱文、皮特·阿贝尔、迈克尔·乔丹和菲利普·莫里茨。信任域策略优化。收录于*国际机器学习会议*，第1889–1897页。PMLR，2015年。

[50] John Schulman、Philipp Moritz、Sergey Levine、Michael Jordan 和 Pieter Abbeel。基于广义优势估计的高维连续控制。*arXiv 预印本 arXiv:1506.02438*，2015。

[51] 约翰·舒尔曼、菲利普·沃尔斯基、普拉富拉·达里瓦尔、亚历克·拉德福德和奥列格·克利莫夫。近端策略优化算法。*arXiv预印本 arXiv:1707.06347*，2017年。

[52] 宋家明、孟晨林和斯特凡诺·埃尔蒙。去噪扩散隐式模型。*arXiv预印本 arXiv:2010.02502*，2020年。

[53] 宋阳、雅沙·索尔-迪克斯坦、迪德里克·P·金马、阿比谢克·库马尔、斯特凡诺·埃尔蒙和本·普尔。基于评分函数的生成建模：通过随机微分方程实现。*arXiv预印本 arXiv:2011.13456*，2020年。

[54] 理查德·S·萨顿和安德鲁·G·巴托。*《强化学习：入门》*。麻省理工学院出版社，2018年。

[55] 唐云浩和希普拉·阿格拉瓦尔。通过归一化流策略增强信任域策略优化。*arXiv预印本 arXiv:1809.10326*，2018。

[56] 保罗·塔菲尔德和雨果·埃利亚斯。《影子机器人模仿人类动作》。*《工业机器人：国际期刊》*，30(1):56–60，2003。

[57] 布拉姆·华莱士、阿卡什·戈库尔和尼希尔·奈克。《Edict：通过耦合变换实现精确扩散反演》。收录于*《IEEE/CVF计算机视觉与模式识别会议论文集》*，第22532–22541页，2023年。

[58] 王方益康、尹虎瑞、董月江、朱虎民浩、赵汉斌、钱慧、李晨等。Belm：用于扩散模型精确反演的双向显式线性多步采样器。*《神经信息处理系统进展》*，37:46118–46159，2024。

[59] 王寅诺、王立坤、江玉轩、邹文俊、刘彤、宋旭杰、王文轩、肖立明、吴江、段景亮等。带熵调节器的扩散式演员-批评者。*神经信息处理系统进展*，37:54183–54204，2024。

[60] 王振东、乔纳森·J·亨特和周明远。作为离线强化学习表达性策略类的扩散策略。收录于*第十一届学习表征国际会议*，2022年。

[61] 吴家龙、吴海旭、邱子涵、王建民和龙明生。离线强化学习的受支持策略优化。*《神经信息处理系统进展》*，35:31278–31291，2022。

[62] 杨龙、黄志雄、雷凤浩、钟玉存、杨一明、方聪、温世廷、周斌斌和林周辰。基于扩散概率模型的强化学习策略表示。*arXiv预印本 arXiv:2305*.13122，2023。

[63] 张国强、Jonathan P Lewis 和 W Bastiaan Kleijn。基于双向积分逼近的精确扩散反演。收录于*《欧洲计算机视觉会议》*，第 19–36 页。Springer，2024。

[64] 张静、张驰、王文佳和景冰怡。基于显式行为密度的离线强化学习约束策略优化。*《神经信息处理系统进展》*，36:5616–5630，2023。

[65] 张钦生和陈永新。扩散归一化流。*《神经信息处理系统进展》*，第34卷：16280–16291页，2021年。

[66] 周文轩、Sujay Bajracharya 和 David Held. Plas：离线强化学习的潜在动作空间。收录于*机器人学习会议*，第 1719–1735 页。PMLR，2021。

[67] 朱正邦、刘明焕、毛丽媛、康冰一、徐敏凯、于勇、斯特凡诺·埃尔蒙和张维南。Madiff：基于扩散模型的离线多智能体学习，2023。

[68] 庄子文、姚申哲、赵航。类人机器人跑酷学习。*arXiv预印本 arXiv:2406.*10759，2024。

A 环境详情

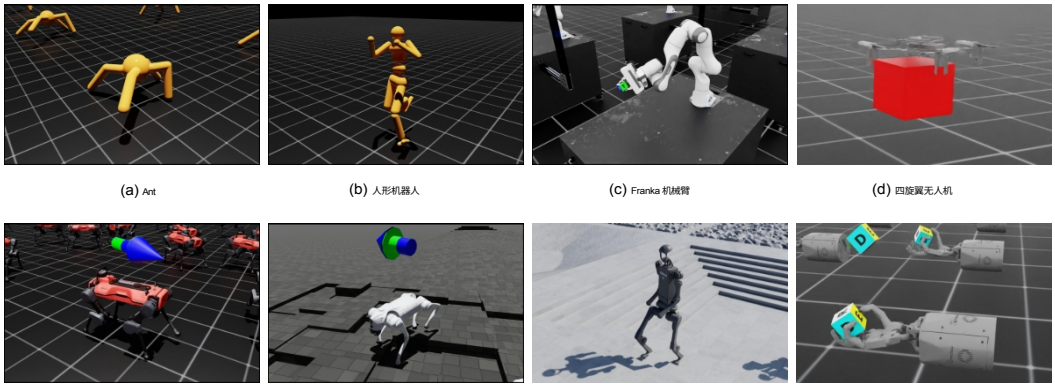

(a) Ant (b) 人形机器人 (c) Franka 机械臂 (d) 四旋翼无人机

(e) AnymalD (f) Unitree-Go2 (g) Unitree-H1 (h) Shadow Hand

图 5：IsaacLab 基准视觉环境（）的八个示例，八张图片来自 `https://isaac-sim.github.io/IsaacLab/main/source/overview/environments.html`。从 (a) 到 (h) 分别为 Isaac-Ant-v0、Isaac-Humanoid-v0、Isaac-Lift-Cube-Franka-v0、 Isaac-Quadcopter-Direct-v0、Isaac-Velocity-Flat-Anymal-D-v0、Isaac-Velocity-Rough-Unitree-Go2-v0、Isaac-Velocity-Rough-H1-v0 以及 Isaac-Repose-Cube-Shadow-Direct-v0。

IsaacLab [2] 是一个用于机器人学习的统一且模块化的框架，旨在简化机器人研究中的常见工作流程，包括强化学习、模仿学习和运动规划。该框架利用 NVIDIA Isaac Sim 进行高保真仿真，并借助 PhysX 的 GPU 加速物理引擎以及基于瓦片的渲染 API 实现向量化渲染。

如图5所示，我们选取了8个具有代表性且具有挑战性的环境，根据Isaaclab的官方手册（`https://isaac-sim.github.io/IsaacLab/main/source/overview/environments.html`：

1. 经典：这些经典任务源自 IsaacGymEnv 对 MuJoCo 风格环境的实现，为连续动作空间中的运动和控制提供了标准化的基准测试。
   - **Isaac-Ant-v0。**状态空间和动作空间分别为 (,) $R^{60\times 8}$ 。该任务涉及控制 MuJoCo Ant 机器人在指定方向上移动。
   - **Isaac-Humanoid-v0。**状态空间和动作空间分别为 (,) $R^{87\times 21}$ 。目标是控制 MuJoCo 类人机器人沿指定方向移动。
2. 操作：此类环境涉及由固定底座机械臂或灵巧机械手执行的操作任务，例如物体取放、抓取或手持旋转。
   - **Isaac-Lift-Cube-Franka-v0。**状态空间和动作空间分别为 (,) $R^{36\times 8}$ 。该任务涉及控制一台Franka Emika机械臂拾取一个立方体并将其运送

     运送到一个随机采样的目标位置。
   - **Isaac-Repose-Cube-Shadow-Direct-v0。**状态空间和动作空间分别为 (,) $R^{157\times 20}$ 。该任务要求使用Shadow灵巧手对立方体进行手内重新定向，使其与目标方向匹配。
3. 移动：该类别涵盖具有腿部结构的移动环境，要求智能体协调多个自由度以实现稳定且有方向的移动。任务包括向前行走、转向和地形适应，通常由类人机器人实现。
   - **Isaac-Velocity-Flat-Anymal-D-v0。**状态空间和动作空间分别为 (,) $R^{48\times 12}$ 。该任务要求控制ANYmal D四足机器人跟随指令

     速度轨迹

[2] https://isaac-sim.github.io/IsaacLab/main/index.html

- **Isaac-Velocity-Rough-Unitree-Go2-v0**。状态空间和动作空间分别为 $(\mathcal{S}, \mathcal{A}) = (\mathbb{R}^{235\times 12}, \mathbb{R}^{12})$。该任务旨在控制一台Unitree Go2四足机器人，使其在崎岖地形上沿给定的速度轨迹行进。
- **Isaac-Velocity-Rough-H1-v0**。状态空间和动作空间分别为 $(\mathcal{S}, \mathcal{A}) = (\mathbb{R}^{256\times 19}, \mathbb{R}^{19})$。该任务涉及控制一台 Unitree H1 类人机器人，使其在崎岖地形上沿给定的速度轨迹。

4. 其他：

- **Isaac-Quadcopter-Direct-v0**。状态空间和动作空间分别为 $(\mathcal{S}, \mathcal{A}) = (\mathbb{R}^{12\times 4}, \mathbb{R}^{4})$。任务是通过应用推力指令。

此外，基于IsaacLab Engine，实验结果可视化的匿名链接见 anonymous-project365.github.io。

B 训练设置

B.1 硬件配置

所有实验均在配备两颗英特尔至强金牌 6430 处理器（每插槽 32 核，每颗处理器共计 64 线程，总计 128 线程）的服务器上进行，其基础频率为 2.1 GHz，最大睿频为 3.4 GHz。该系统支持 52 位物理寻址和 57 位虚拟寻址。 在GPU加速方面，我们使用了8块NVIDIA GeForce RTX 4090 D GPU，每块配备24 GB GDDR6X内存，通过PCIe接口连接。这些GPU支持CUDA 12.8，运行于NVIDIA驱动程序版本570.124.04。该机器采用跨2个节点的NUMA拓扑结构，每个节点处理64个逻辑CPU。 实验过程中未启用 GPU MIG（多实例 GPU）或 ECC 功能。

B.2 IsaacLab中的强化学习框架

IsaacLab 提供了与多个强化学习库的原生集成，包括 RSL-RL https://github.com/leggedrobotics/rsl_rl、RL-Games https://github.com/Denys88/rl_games、SKRL https://skrl.readthedocs.io/en/latest/ 以及 Stable-Baselines3 https://stable-baselines3.readthedocs.io/en/master/index.html，这些库各自提供了用于代理与环境交互的独特 API。 在本研究中，我们采用 SKRL 作为实现基线算法的主要框架。 SKRL 是一个开源、模块化且可扩展的库，提供了广泛使用的强化学习方法的标准化实现。具体而言，我们利用其对 PPO https://skrl.readthedocs.io/en/latest/api/agents/ppo.html、SAC https://skrl.readthedocs.io/en/latest/api/agents/sac.html、TD3 https://skrl.readthedocs.io/en/latest/api/agents/td3.html，以及 DDPG https://skrl.readthedocs.io/en/latest/api/agents/ddpg.html 进行基线评估。对于 QVPO 和 DACER 等算法，我们设计了自定义环境封装器，以适配现有接口，而无需修改底层仿真环境。 我们提出的方法 GenPO 采用 RSL-RL 进行实现，这是一个专为机器人学和连续控制量身定制的轻量级、高性能框架，其设计重点在于计算效率和部署便捷性。

B.3 超参数

表 2 和表 10 总结了我们在各项实验中使用的超参数配置。对于基线算法：PPO、SAC、TD3 和 DDPG，我们采用了 SKRL 库提供的默认超参数设置。对于我们提出的方法 GenPO，我们将其超参数配置与 PPO 保持一致，以确保比较的公平性和可控性。

表 2：Isaaclab-Ant-v0.

超参数	GenPO	PPO	QVPO	DACER	SAC	TD3	DDPG
演员网络中的隐藏层	[400,200,100]	[400,200,100]	[256,256,256]	[256,256,256]	[400,200,100]	[400,200,100]	[400,200,100]
批评网络中的隐藏层	[400,200,100]	[400,200,100]	[256,256,256]	[256,256,256]	[400,200,100]	[400,200,100]	[400,200,100]
激活	mish	elu	mish	relu	mish	mish	mish
批处理大小	4096	4096	4096	4096	4096	4096	4096
使用 GAE	True	True	不适用	不适用	不适用	不适用	不适用
奖励 γ的折扣	0.99	0.99	0.99	0.99	0.99	0.99	0.99
GAE平滑参数 λ	0.95	0.95	不适用	不适用	不适用	不适用	不适用
演员的学习率	1×10^{-3}	1×10^{-3}	3×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}
批评者的学习率	1×10^{-3}	1×10^{-3}	3×10^{-4}	3×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}
演员-批评家梯度范数	1.0	1.0	1.0	1.0	1.0	1.0	1.0
内存大小	不适用	不适用	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}
熵系数	0.01	0.01	不适用	不适用	不适用	不适用	不适用
值损耗系数	1.0	1.0	1.0	1.0	1.0	1.0	1.0
噪声片段	不适用	不适用	不适用	0.5	不适用	不适用	不适用
替代片段	0.2	0.2	不适用	不适用	不适用	不适用	不适用
扩散步骤	5	不适用	20	20	不适用	不适用	不适用
目标KL	0.01	0.01	不适用	不适用	不适用	不适用	不适用

表 3：Isaaclab-Humanoid-v0.

超参数	GenPO	PPO	QVPO	DACER	SAC	TD3	DDPG
演员网络中的隐藏层	[400,200,100]	[400,200,100]	[256,256,256]	[256,256,256]	[400,200,100]	[400,200,100]	[400,200,100]
批评网络中的隐藏层	[400,200,100]	[400,200,100]	[256,256,256]	[256,256,256]	[400,200,100]	[400,200,100]	[400,200,100]
激活	mish	elu	mish	relu	mish	mish	mish
批处理大小	4096	4096	4096	4096	4096	4096	4096
使用 GAE	True	True	不适用	不适用	不适用	不适用	不适用
奖励 γ的折扣	0.99	0.99	0.99	0.99	0.99	0.99	0.99
GAE平滑参数 λ	0.95	0.95	不适用	不适用	不适用	不适用	不适用
演员的学习率	5×10^{-4}	5×10^{-4}	3×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}
批评者的学习率	5.0×10^{-4}	5.0×10^{-4}	5.0×10^{-4}	5.0×10^{-4}	5.0×10^{-4}	5.0×10^{-4}	5×10^{-4}
演员-批评家梯度范数							1.0
内存大小	不适用	不适用	不适用	不适用	不适用	不适用	1×10^{6}
熵系数	0.01	0.01					不适用
值损耗系数	1.0	1.0	1.0	1.0	1.0	1.0	1.0
噪声片段	不适用	不适用	不适用	0.5	不适用	不适用	不适用
替代片段	0.2	0.2	不适用	不适用	不适用	不适用	不适用
扩散步骤	5	不适用	20	20	不适用	不适用	不适用
目标KL	0.01	0.01	不适用	不适用	不适用	不适用	不适用

表 4：Isaac-Lift-Cube-Franka-v0.

超参数	GenPO	PPO	QVPO	DACER	SAC	TD3	DDPG
演员网络中的隐藏层	[256,128,64]	[256,128,64]	[256,256,256]	[256,256,256]	[256, 128, 64]	[256, 128, 64]	[256, 128, 64]
批评网络中的隐藏层	[256,128,64]	[256,128,64]	[256,256,256]	[256,256,256]	[256, 128, 64]	[256, 128, 64]	[256, 128, 64]
激活	混合	elu	mish	relu	mish	mish	mish
批处理大小	4096	4096	4096	4096	4096	4096	4096
使用 GAE	True	True	不适用	不适用	不适用	不适用	不适用
奖励 γ的折扣	0.98	0.98	0.99	0.99	0.99	0.99	0.99
GAE平滑参数 λ	0.95	0.95	不适用	不适用	不适用	不适用	不适用
演员的学习率	1×10^{-4}	1×10^{-4}	3×10^{-4}	5×10^{-4}	1×10^{-4}	1×10^{-4}	1×10^{-4}
批评者的学习率	1.0×10^{-4}	1.0×10^{-4}	3.0×10^{-4}	3.0×10^{-4}	1.0×10^{-4}	1.0×10^{-4}	1×10^{-4}
演员-批评家梯度范数							1.0
内存大小	不适用	不适用	不适用	不适用	不适用	不适用	1×10^{6}
熵系数	0.006	0.006	1×10^{-2}	1×10^{-2}	1×10^{-2}	1×10^{-2}	不适用
值损耗系数	1.0	1.0	1.0	1.0	1.0	1.0	1.0
噪声片段	不适用	不适用	不适用	0.5	不适用	不适用	不适用
替代片段	0.2	0.2	不适用	不适用	不适用	不适用	不适用
扩散步骤	5	不适用	20	20	不适用	不适用	不适用
目标KL	0.01	0.01	不适用	不适用	不适用	不适用	不适用

表 5：Isaac-Quadcopter-Direct-v0.

超参数	GenPO	PPO	QVPO	DACER	SAC	TD3	DDPG 演员
网络中的隐藏层 [64,64]	[64,64]	[256,256,256]	[256,256,256]	[64, 64][64, 64]	[64, 64]		
批评网络中的隐藏层 [64,64]	[64,64]	[256,256,256]	[256,256,256] [64, 64]	[64, 64]	[64, 64] 激活	mish	elu
	mish	relu	mish	mish	mish 批处理大小	4096	4096
	4096	4096	4096	4096	4096		
使用 GAE	True	True	不适用	不适用	不适用	不适用	不适
用 奖励 γ的折扣	0.99	0.99	0.99	0.99	0.99	0.99	0.99
GAE平滑参数 λ	0.95	0.95	不适用	不适用	不适用	不适用	不适用 执行
器的学习率	5×10^{-4}	5×10^{-4}	3×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}
批评者的学习率	5×10^{-4}	5×10^{-4}	3×10^{-4}	3×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}
演员-评论家梯度正则化	1.0	1.0	1.0	1.0	1.0	1.0	1.0
内存容量	不适用	不适用	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}
熵系数	0.01	0.01	不适用	不适用	不适用	不适用	不适
用 价值损失系数	1.0	1.0	1.0	1.0	1.0	1.0	1.0
噪音片段	不适用	不适用	不适用	0.5	不适用	不适用	不 适
用替代片段	0.2	0.2	不适用	不适用	不适用	不适用	不 适
用扩散步骤	5	不适用	20	20	不适用	不适用	不 适
用目标KL	0.01	0.01	不适用	不适用	不适用	不适用	不 适
用							

表 6：Isaac-Velocity-Flat-Anymal-D-v0.

超参数	GenPO	PPO	QVPO	DACER	SAC	TD3	DDPG
演员网络中的隐藏层 [128,128,128]	[128,128,128]	[256,256,256]	[256,256,256]	[128, 128, 128]	[128, 128, 128]	[128, 128, 128]	
Critic网络中的隐藏层 [128,128,128]	[128,128,128]	[256,256,256]	[256,256,256]	[128, 128, 128]	[128, 128, 128]	[128, 128, 128]	
激活	混合	elu	mish	relu	mish	mish	mish 批
处理大小	4096	4096	4096	4096	4096	4096	4096
使用 GAE	True	True	不适用	不适用	不适用	不适用	不适
用 奖励 γ的折扣	0.99	0.99	0.99	0.99	0.99	0.99	0.99
GAE平滑参数 λ 0.95	0.95	不适用	不适用	不适用	不适用	不适用 执行器的学习率	1×10^{-3}
	1×10^{-33}	3×10^{-104}	5×10^{-4}	1×10^{-3}	1×10^{-3}	1×10^{-3}	
批评者的学习率	1×10^{-3}	1×10^{-3}	3×10^{-104}	3×10^{-4}	1×10^{-3}	1×10^{-3}	1×10^{-3}
演员-批评家梯度规范	1.0	1.0	1.0	1.0	1.0	1.0	1.0
内存容量	不适用	不适用	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}
熵系数	0.005	0.005	不适用	不适用	不适用	不适用	不适
用 价值损失系数	1.0	1.0	1.0	1.0	1.0	1.0	1.0
噪音片段	不适用	不适用	不适用	0.5	不适用	不适用	不 适
用替代片段	0.2	0.2	不适用	不适用	不适用	不适用	不 适
用扩散步骤	5	不适用	20	20	不适用	不适用	不 适
用目标KL	0.01	0.01	不适用	不适用	不适用	不适用	不 适
用							

表 7：Isaac-Velocity-Rough-Unitree-Go2-v0.

超参数	GenPO	PPO	QVPO	DACER	SAC	TD3	DDPG
演员网络中的隐藏层 [512, 256, 128]	[512, 256, 128]	[256,256,256]	[256,256,256]	[512, 256, 128]	[512, 256, 128]	[512, 256, 128]	
Critic网络中的隐藏层 [512, 256, 128]	[512, 256, 128]	[256,256,256]	[256,256,256]	[512, 256, 128]	[512, 256, 128]	[512, 256, 128]	
激活	混合	elu	mish	relu	mish	mish	mish 批
处理大小	4096	4096	4096	4096	4096	4096	4096
使用 GAE	True	True	不适用	不适用	不适用	不适用	不适
用 奖励 γ的折扣	0.99	0.99	0.99	0.99	0.99	0.99	0.99
GAE平滑参数 λ 0.95	0.95	不适用	不适用	不适用	不适用	不适用 执行器的学习率	1×10^{-3}
	1×10^{-33}	3×10^{-104}	5×10^{-4}	1×10^{-3}	1×10^{-3}	1×10^{-3}	
批评者的学习率	1×10^{-3}	1×10^{-3}	3×10^{-104}	3×10^{-4}	1×10^{-3}	1×10^{-3}	1×10^{-3}
演员-批评家梯度正则化	1.0	1.0	1.0	1.0	1.0	1.0	1.0
内存容量	不适用	不适用	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}
熵系数	0.01	0.01	不适用	不适用	不适用	不适用	不适

用 价值损失系数	1.0	1.0	1.0	1.0	1.0	1.0	1.0
噪音片段	不适用	不适用	不适用	0.5	不适用	不适用	不 适
用替代片段	0.2	0.2	不适用	不适用	不适用	不适用	不 适
用扩散步骤	5	不适用	20	20	不适用	不适用	不 适
用目标KL	0.01	0.01	不适用	不适用	不适用	不适用	不 适
用							

表 8：Isaac-Velocity-Rough-H1-v0 模型中使用的超参数。

超参数	GenPO	PPO	QVPO	DACER	SAC	TD3	DDPG
演员网络中的隐藏层	[512, 256, 128]	[512, 256, 128]	[256,256,256]	[256,256,256]	[512, 256, 128]	[512, 256, 128]	[512, 256, 128]
Critic网络中的隐藏层	[512, 256, 128]	[512, 256, 128]	[256,256,256]	[256,256,256]	[512, 256, 128]	[512, 256, 128]	[512, 256, 128]
激活	混合	elu	mish	relu	mish	mish	mish 批
处理大小	4096	4096	4096	4096	4096	4096	4096
使用 GAE	True	True	不适用	不适用	不适用	不适用	不适
用 奖励 γ的折扣	0.99	0.99	0.99	0.99	0.99	0.99	0.99
GAE平滑参数 λ 0.95	0.95	不适用	不适用	不适用	不适用	不适用 执行器的学习率	1×10^{-3}
批评者的学习率	1×10^{-3}	3×10^{-4}	5×10^{-4}	1×10^{-3}	1×10^{-3}	1×10^{-3}	1×10^{-3}
演员-批评家梯度正则化	1.0×10^{-3}	1.0×10^{-3}	1.0×10^{-4}	1.0×10^{-4}	1.0×10^{-4}	1.0×10^{-4}	1.0×10^{-4}
内存容量	不适用	不适用	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}
熵系数	0.01	0.01	不适用	不适用	不适用	不适用	不适
用 价值损失系数	1.0	1.0	1.0	1.0	1.0	1.0	1.0
噪音片段	不适用	不适用	不适用	0.5	不适用	不适用	不 适
用替代片段	0.2	0.2	不适用	不适用	不适用	不适用	不 适
用扩散步骤	5	不适用	20	20	不适用	不适用	不 适
用目标KL	0.01	0.01	不适用	不适用	不适用	不适用	不 适

用

表 9：Isaac-Repose-Cube-Shadow-Direct-v0.

超参数	GenPO	PPO	QVPO	DACER	SAC	TD3	DDPG
演员网络中的隐藏层	[512, 512, 256, 128]	[512, 512, 256, 128]	[256,256,256]	[256,256,256]	[512, 512, 256, 128]	[512, 512, 256, 128]	[512, 512, 256, 128]
Critic网络中的隐藏层	[512, 512, 256, 128]	[512, 512, 256, 128]	[256,256,256]	[256,256,256]	[512, 512, 256, 128]	[512, 512, 256, 128]	[512, 512, 256, 128]
激活	mish	elu	mish	relu	mish	mish	mish 批
处理大小	4096	4096	4096	4096	4096	4096	4096
使用 GAE	True	True	不适用	不适用	不适用	不适用	不适用
奖励 γ的折扣	0.99	0.99	0.99	0.99	0.99	0.99	0.99
GAE平滑参数 λ 0.95	0.95	不适用	不适用	不适用	不适用	不适用 执行器的学习率	5×10^{-4}
批评者的学习率	5×10^{-4}	3×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}	5×10^{-4}
演员-评论家梯度正则化	1.0×10^{-4}	1.0×10^{-4}	1.0×10^{-4}	1.0×10^{-4}	1.0×10^{-4}	1.0×10^{-4}	1.0×10^{-4}
内存容量	不适用	不适用	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}	1×10^{6}
熵系数	0.005	0.005	不适用	不适用	不适用	不适用	不适用
价值损失系数	1.0	1.0	1.0	1.0	1.0	1.0	1.0
噪音片段	不适用	不适用	不适用	0.5	不适用	不适用	不适用
替代片段	0.2	0.2	不适用	不适用	不适用	不适用	不适用
扩散步骤	5	不适用	20	20	不适用	不适用	不适用
目标KL	0.016	0.016	不适用	不适用	不适用	不适用	不适用

表 10：GenPO 中使用的超参数。

超参数	Ant	人形机器人	Franka 机械臂	四旋翼	Anymal-D	Unitree-Go2	Unitree-H1	影子之手
压缩系数 λ	0.01	0.01	0.01	0.01	0.01	0.01	0.01	0.01
时间嵌入维度	32	32	32	16	32	32	32	32
时间嵌入中的隐藏层	[256,256]	[256,256]	[256,256]	[128,128]	[256,256]	[256,256]	[256,256]	[256,256]
混合系数 p	0.9	0.9	0.9	0.9	0.9	0.9	0.9	0.9

C 模型架构详情

C.1 正弦位置嵌入

在训练过程中，我们不直接将时间步 t、状态 s_t和动作 a_t 作为原始输入特征进行拼接，而是引入正弦位置嵌入来编码时间维度。这种方法受去噪扩散

概率模型（DDPMs）中常用的位置编码技术，将每个时间步 $t \in \{0, 1, \ldots, T\}$ 映射为一个固定维度的向量

$e_t \in \mathbb{R}^d$，具体如下：

$$e_t^{(2i)} = \sin\left(\frac{t}{10000^{2i/d}}\right), \quad e_t^{(2i+1)} = \cos\left(\frac{t}{10000^{2i/d}}\right), \quad \text{当 } i = 0, 1, \ldots, \frac{d}{2} - 1 \text{ 时。} \tag{13}$$

随后，所得的嵌入向量 e_t 会被输入到多层感知器（MLP）中，以进行非线性变换并投影到模型的特征空间中。随后，将 MLP 的输出与状态 s_t和动作 a_t 拼接，形成最终的输入表示：

$$\tilde{x}_t = \mathrm{concat}(s_t, a_t, \mathrm{MLP}(e_t)), \tag{14}$$

这为模型输入增添了平滑、连续的时间进程表示。与原始标量时间步长拼接不同，正弦嵌入提供了一种结构化编码，

有助于模型推断时间关系和顺序，即使在没有显式递归或注意力机制的情况下也是如此。

C.2 演员与评论家模型架构

在 Isaac-Ant-v0 环境中，与流量策略相对应的执行器网络被实现为一个具有 [400,200,100] 隐藏层维度的多层感知器（MLP）。 所使用的激活函数为 Mish。执行器的输入由当前状态、动作以及正弦时间嵌入向量的拼接组成，从而得到输入维度为 + + ，输出维度等于动作维度 ，这代表了基于流的动作细化。 批评者网络同样实现为多层感知机，具有相同的隐藏层结构 [400,200,100] 和 Mish 激活函数。它仅接收当前状态作为输入，并输出一个对应于估计状态值的标量值。 |A| |S| |T |

|A|

D 补充实验

D.1 不同并行环境规模的影响

为了评估并行化对GenPO学习效率的影响，我们进行了一项实验，通过改变并行环境数量来考察其影响。我们分别使用512、1024、2048、4096和8192个并行环境对GenPO代理进行了训练。所有其他超参数在这些运行中均保持一致。

如图6所示，增加并行环境数量通常会提升学习性能。与使用较少环境训练的智能体相比，使用更多环境训练的智能体收敛速度更快，且最终获得的奖励更高。然而，与使用4096个环境相比，使用8192个环境所带来的性能提升微乎其微。为了平衡性能与计算效率，我们在所有实验中将并行环境数量固定为4096。

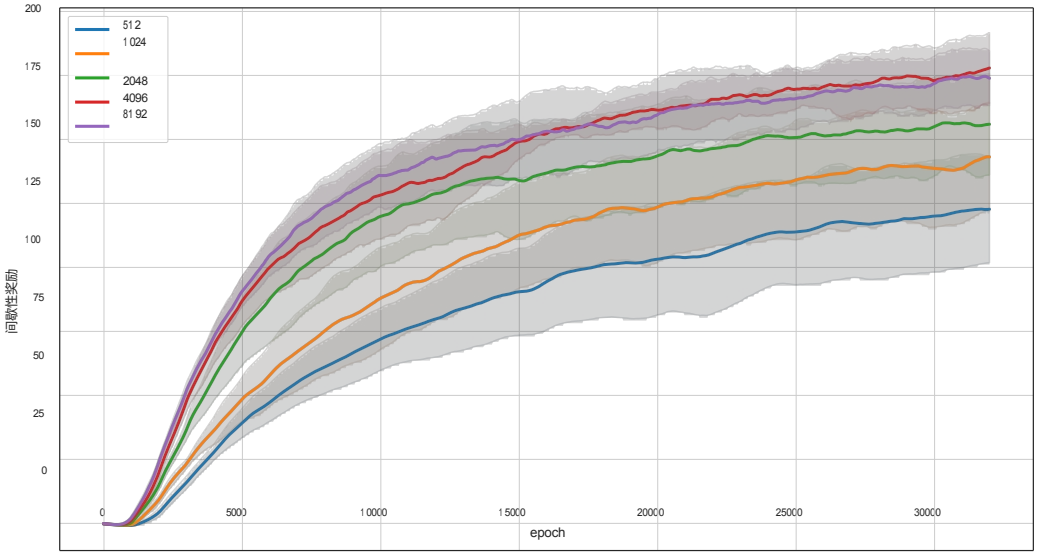

图 6： 在Isaaclab-Ant-v0基准测试中，不同并行环境数量下的学习曲线。结果为5次运行的平均值。x轴表示训练 epoch，y轴显示平均回合回报，并以阴影标出一个标准差。

D.2 不同流量策略步长的影响

我们研究了流量步骤数（记为 T）对学习性能的影响。为此，我们在保持所有其他超参数固定的情况下，使用不同的 T 值（ 1, 2, 5, 10, 20）对代理进行训练。如图 7 所示，流量步骤数会影响收敛性 ∈ { }

速度和性能稳定性。值得注意的是，只要 T 值不至于过小（例如 $T \geq 2$），整体性能依然稳健。

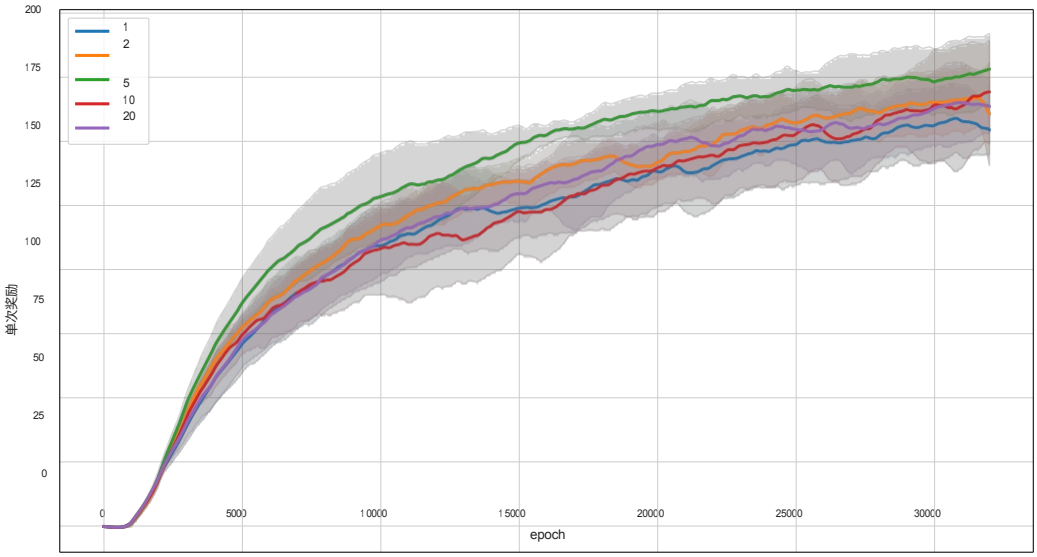

图 7：Isaaclab-Ant-v0 基准测试中不同流量 策略时间步长下的学习曲线。结果为 5 次运行的平均值。x 轴表示训练 epoch，y 轴显示平均局次回报，并以阴影标出一个标准差。

D.3 不同操作对虚拟动作空间的影响

我们研究了通过对虚拟动作 $\tilde{a} = (x, y)$ 的两个部分分量 x 和 y 进行插值，从而恢复单个动作所产生的影响。具体而言，我们将真实动作构造为 $\alpha x + (1-\alpha) y$，其中 α 分别取值于 0.0、0.3、0.5、0.7、1.0，且 0.0、0.3、0.5、0.7、1.0， 。 如图 8 所示，当 $\alpha = 0.5$ 时性能最佳。这一观察结果突显了均衡利用虚拟动作两个分量的优势。当 $\alpha = 0.0$ 或 $\alpha = 1.0$ 时，仅利用了虚拟动作空间的一侧，导致探索受限且性能不佳。 相比之下，在两个分量之间进行插值可以增强探索多样性并提高采样效率，这对在高维或多模态动作空间中进行有效的策略优化至关重要。

D.4 时间步长嵌入的影响

我们研究了正弦时间嵌入对流量策略性能的影响。如图9所示，引入正弦嵌入显著提升了策略在扩散过程不同阶段利用时序信息的能力。 正弦编码提供的结构化高维表示有助于更好地区分时间步，进而增强模型学习有效去噪函数的能力。相比之下，将标量时间步与状态和动作简单拼接无法提供充分的时间结构，导致性能下降。基于这些观察结果，我们在后续所有实验中采用正弦位置嵌入来编码时间步。

D.5 训练与推理时间

为了验证计算效率，我们还针对所提出的GenPO与其他6种基线模型进行了对比实验，分别评估了在单GPU和多GPU环境下的推理、训练及并行训练时间，如图10、图11和图12所示。可以看出，尽管由于多

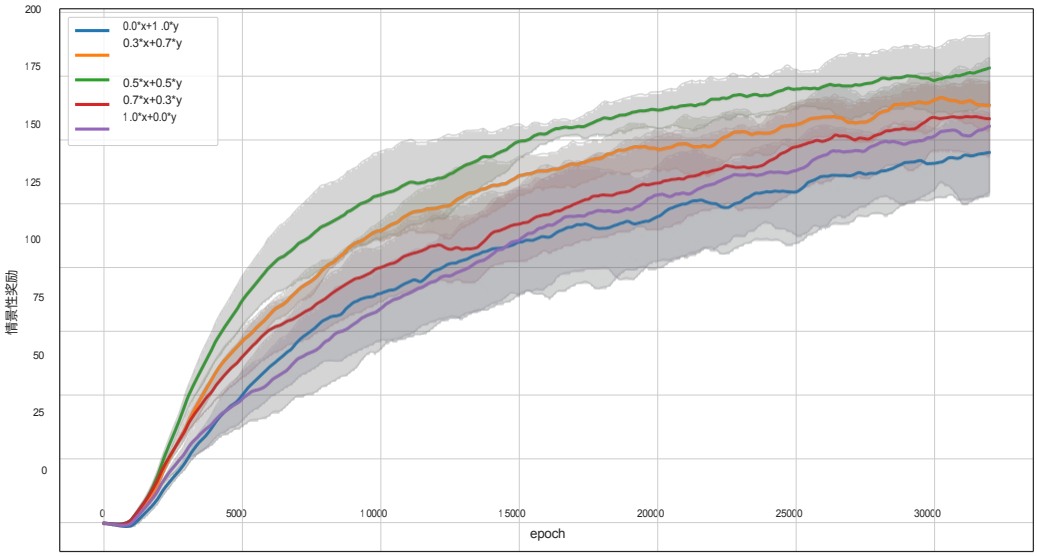

图 8：在 Isaaclab-Ant-v0 基准测试中，针对虚拟动作空间的不同 操作的学习曲线。结果为 5 次运行的平均值。x 轴表示训练 epoch，y 轴显示平均回合回报，并以阴影标出一个标准差。

在减少扩散的迭代次数后，其效率仍显著高于QVPO和DACER等基于扩散的传统强化学习算法。此外，据我们所知，2.577毫秒的推理时间完全足以满足机器人控制中的实时决策需求。 此外，在训练时间方面，尽管 GenPO 在单张 GPU 上的表现未达理想（但仍优于先前的扩散式强化学习方法），它能有效利用多 GPU 并行计算来显著加速训练。相比之下，传统的强化学习算法 PPO 则无法明显受益于此。

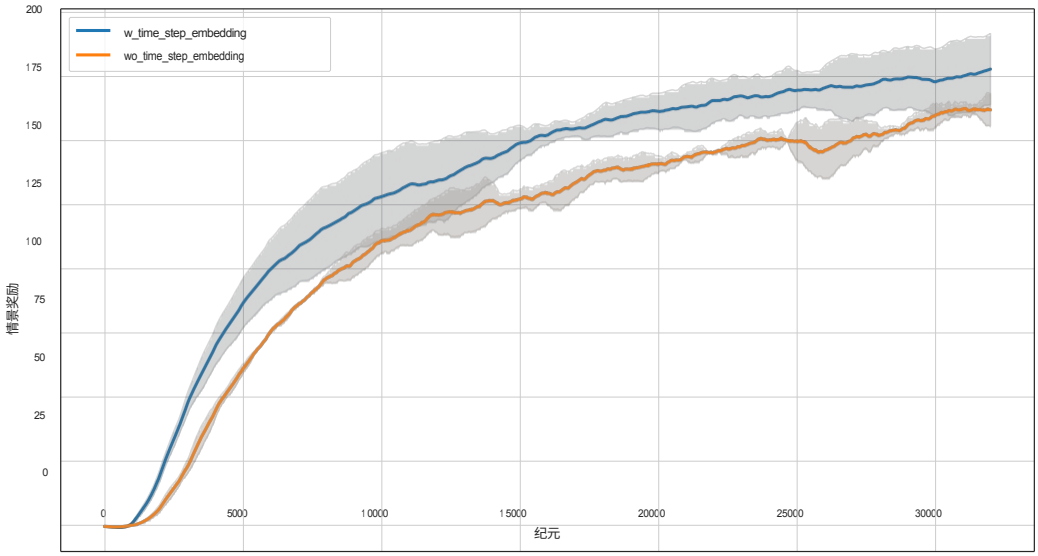

图 9：在 的 Isaaclab-Ant-v0 基准测试中，采用或不采用时间步正弦位置嵌入的学习曲线。结果为 5 次运行的平均值。x 轴表示训练 epoch 数，y 轴显示平均回合回报，并以阴影标出一个标准差。

E 引理 1 的证明

引理 1. ***(变量变换 [3])*** *设* $f : \mathbb{R}^n \to \mathbb{R}^n$ *是一个可逆且光滑的映射。若随机变量* $X \sim q(x)$ *及经函数* f *变换后的随机变量* $Y = f(X)$ *存在，则* Y *的分布* $p(y)$ *为*

$$p(y) = q(x) \det \left(\frac{\partial f}{\partial x} \right)^{-1}. \tag{15}$$

证明。 这里，我们以一维随机变量 X、Y 为例。对于一般的 n 维情况，通过应用多元微积分，我们可以得到相同的结果。

首先，由于 f 是可逆且光滑的映射，我们可以将 f 分为两类：(1) f 是严格递增的，(2) f 是严格递减的。

严格递增。 对于严格递增*的* f，Y 的累积分布函数为

$$P(y) = P(Y \le y) = P(f(X) \le y) = P(X \le f^{-1}(y)) = Qf^{-1}(y) = Q(x)。$$

那么，根据 $p(x) = \lim_{\epsilon \to 0} \frac{P(x+\epsilon)-P(x)}{\epsilon}$ 以及链式法则，随机变量 Y 的概率密度函数为

$$p(y) = q(x) \left| \frac{dx}{dy} \right| = q(x) \left| \det \left(\frac{\partial f}{\partial x} \right)^{-1} \right|.$$

严格递减。 f 严格递减的证明与此类似。在这种情况下，Y 的概率密度函数为

$p(y) = -q(x) \frac{dx}{dy}$ 因为 $\frac{dx}{dy} < 0$。因此，我们需要在最终公式中加上一个绝对值符号，即

$p(y) = q(x) \det \left(\frac{\partial f}{\partial x} \right)^{-1}$. □

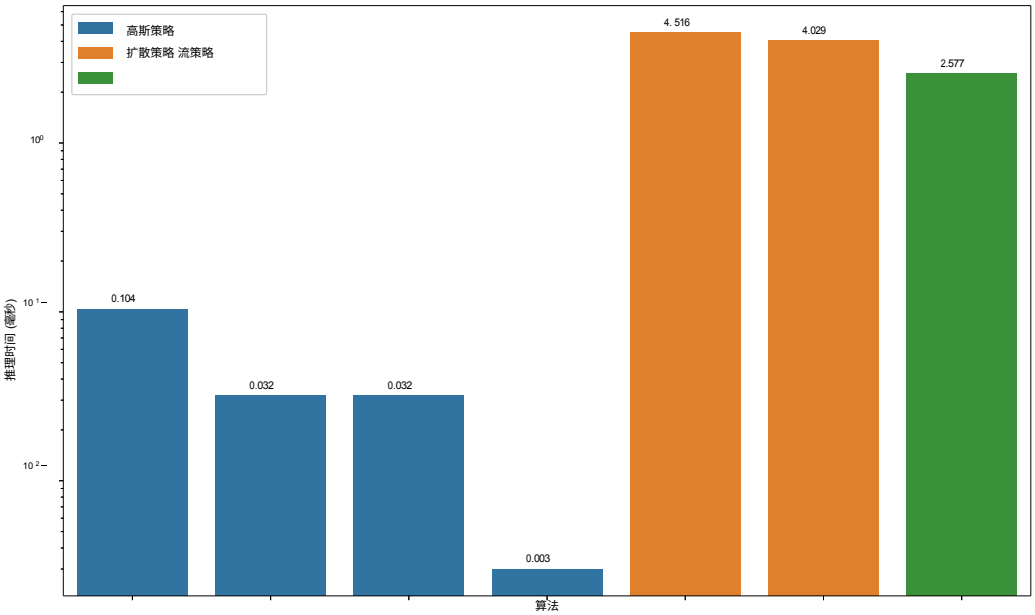

图 10：在 Issac-Ant-v0 环境下对 的推理时间进行比较。

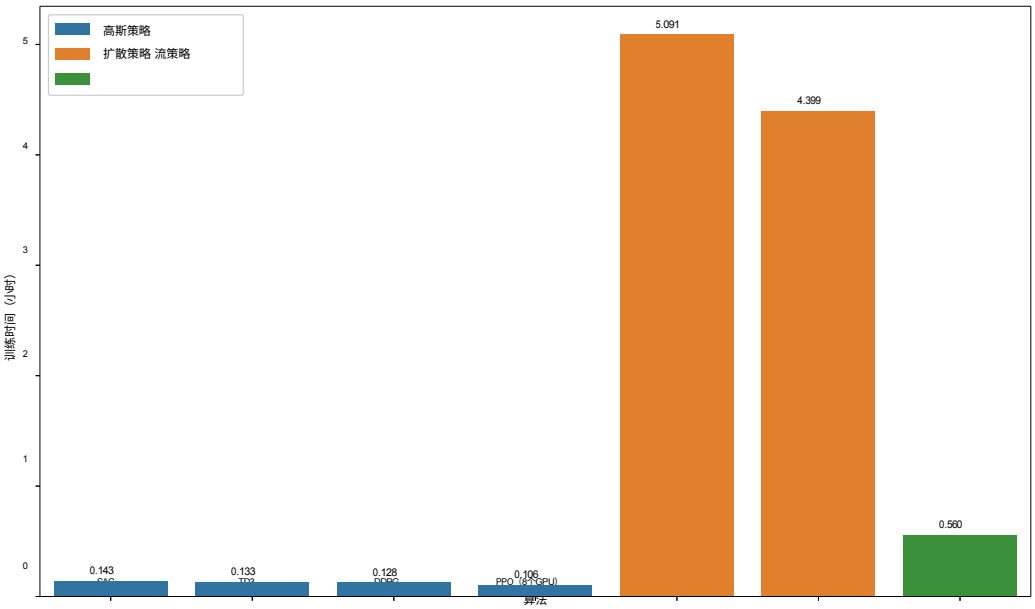

图 11：在 Isaac-Ant-v0 环境下对 的训练时间比较。

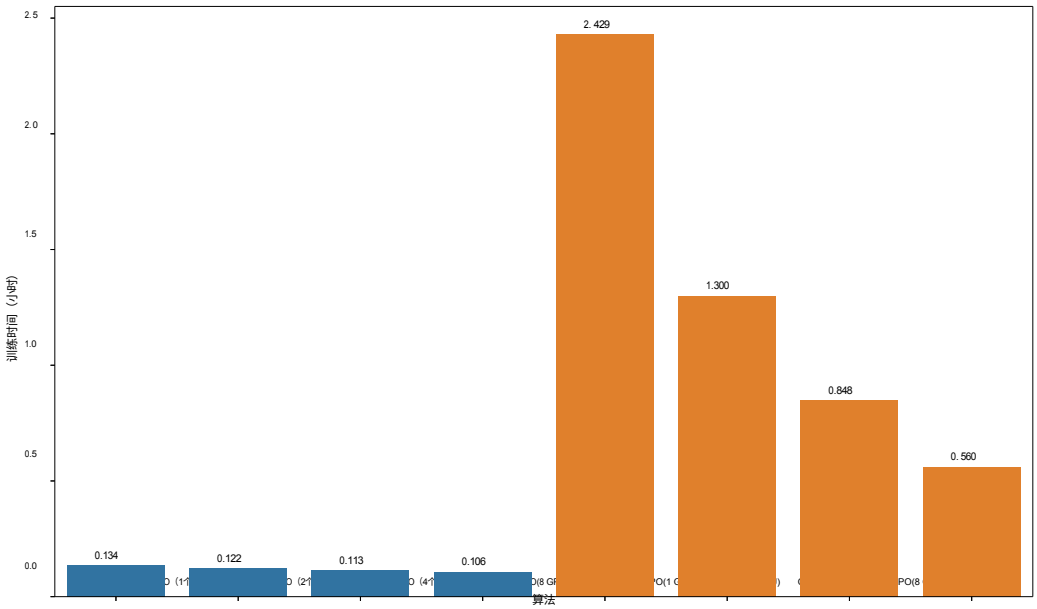

图 12：在 Isaac-And-v0 环境中， PPO 与 GenPO 在多 GPU 训练扩展方面的训练时间对比。

NeurIPS论文检查清单

1. **主张**

   问题：摘要和引言中提出的主要主张是否准确反映了论文的贡献和范围？

   回答：[是]

   理由：如摘要和引言所述，本文弥合了基于策略的强化学习与生成式扩散模型之间的鸿沟，使得在扩散策略中计算对数似然成为可能，并最终使大规模并行模拟环境能够利用扩散模型强大的多模态能力。这些内容能够准确反映本文的贡献和研究范围。

   指南：

   - 答案“NA”表示摘要和引言中未包含论文中提出的论点。
   - 摘要和/或引言应明确阐述论文的论点，包括论文的贡献以及重要的假设和局限性。若对此问题回答“否”或“NA”，评审人将不予好评。
   - 提出的论点应与理论和实验结果相符，并反映出这些结果在多大程度上可推广至其他场景。
   - 将远大目标作为研究动机纳入其中是可以的，只要明确说明这些目标尚未在本论文中实现。

2. **局限性**

   问题：论文是否讨论了作者所做工作的局限性？ 答案：[是]

   理由：第6节中提供了对局限性的分析。指南：

   - 选项“NA”表示该论文没有局限性，而选项“No”表示该论文存在局限性，但论文中未对此进行讨论。
   - 鼓励作者在论文中单独设立“局限性”一节。
   - 论文应指出任何强假设，以及结果在这些假设被违反时的稳健性（例如，独立性假设、无噪声设置、模型规格合理性、仅在局部成立的渐近近似）。作者应思考这些假设在实践中可能如何被违反，以及由此会产生什么影响。
   - 作者应审视所提出结论的适用范围，例如该方法是否仅在少数数据集上或经过少量运行测试。通常，实证结果往往依赖于隐含的假设，这些假设应予以阐明。
   - 作者应探讨影响该方法性能的因素。例如，当图像分辨率较低或拍摄环境光线不足时，人脸识别算法的性能可能不佳；或者，语音转文本系统可能无法可靠地为在线讲座提供字幕，因为它无法处理专业术语。
   - 作者应讨论所提算法的计算效率及其随数据集规模扩展的表现。
   - 如果适用，作者应讨论其解决隐私和公平性问题的方法可能存在的局限性。
   - 虽然作者可能担心，若完全坦诚地说明局限性，可能会被审稿人作为拒稿的理由，但更糟糕的结果可能是审稿人发现论文中未提及的局限性。作者应运用自己的最佳判断，并认识到个人为促进透明度所采取的行动，在建立维护学术社区诚信的规范方面发挥着重要作用。我们将特别指示审稿人，不得因作者对局限性的坦诚而予以扣分。

3. **理论假设与证明**

问题：对于每个理论结果，论文是否提供了完整的假设集以及完整（且正确）的证明？

回答：[是]

说明：证明详见补充材料。指南：

- 答案“NA”表示该论文未包含理论结果。
- 论文中的所有定理、公式和证明均应编号并相互引用。
- 所有假设均应在定理陈述中明确说明或予以引用。
- 证明可置于正文或补充材料中，但若置于补充材料中，建议作者提供简短的证明概要以帮助理解。
- 反之，论文正文中提供的任何非形式化证明，都应辅以附录或补充材料中提供的形式化证明。
- 证明所依赖的定理和引理应予以恰当引用。

4. **实验结果的可重复性**

问题：本文是否充分披露了所有必要信息，以便重现影响论文主要主张和/或结论的实验结果（无论是否提供了代码和数据）？

回答：[是]

理由：这些细节已在补充材料中提供。指南：

- 答案“NA”表示该论文未包含实验。
- 如果论文包含实验，对此问题回答“否”将不会受到审稿人的好评：无论是否提供了代码和数据，确保论文结果可重复都是至关重要的。
- 如果贡献是一组数据集和/或模型，作者应描述为使结果可重现或可验证而采取的步骤。
- 根据具体贡献的不同，可重现性可以通过多种方式实现。例如，如果贡献是一套新型架构，那么完整描述该架构可能就已足够；如果贡献是一个特定模型及其经验性评估，则可能需要确保他人能够使用相同的数据集复现该模型，或者提供对该模型的访问权限。 一般而言，发布代码和数据通常是实现可重复性的一种有效方式，但也可通过提供详细的复现指南、开放托管模型的访问权限（例如大型语言模型）、发布模型检查点，或采用其他适合该研究的手段来确保可重复性。
- 虽然NeurIPS并不要求公开代码，但会议要求所有投稿都应提供某种合理的可复现途径，具体方式可能取决于研究成果的性质。例如
  (a) 如果研究成果主要是一种新算法，论文应明确说明如何复现该算法。
  (b) 如果该成果主要是一种新的模型架构，论文应清晰且完整地描述该架构。
  (c) 如果该成果是一个新模型（例如大型语言模型），则应提供两种方式之一：要么能够访问该模型以复现结果，要么能够复现该模型（例如提供开源数据集或构建数据集的说明）。
  (d) 我们认识到，在某些情况下，可重复性可能难以实现；在此情况下，欢迎作者说明其确保可重复性的具体方法。对于闭源模型，虽然对模型的访问可能受到某种限制（例如仅限注册用户），但其他研究人员仍应能够通过某种途径重现或验证结果。

5. **数据与代码的开放获取**

问题：本文是否提供了数据和代码的开放访问，并附有充分的说明，以便如补充材料所述，忠实重现主要实验结果？

回答：[是]

说明：论文一经录用，我们将发布代码。指南：

- 答案“NA”表示该论文未包含需要代码支持的实验。
- 更多详情请参阅NeurIPS代码与数据提交指南（https://nips.cc/public/guides/CodeSubmissionPolicy）。
- 虽然我们鼓励公开代码和数据，但我们也理解这在某些情况下可能无法实现，因此“不公开”也是可以接受的答案。论文不会仅因未包含代码而被拒稿，除非代码是该论文贡献的核心（例如，针对新的开源基准测试）。
- 说明中应包含重现结果所需的精确命令和环境。请参阅 NeurIPS 代码和数据提交指南（https://nips.cc/public/guides/CodeSubmissionPolicy) 以获取更多详情。
- 作者应提供数据访问和准备说明，包括如何访问原始数据、预处理数据、中间数据和生成数据等。
- 作者应提供脚本，以便重现所提新方法及基线的所有实验结果。若仅部分实验可重现，应说明脚本中遗漏了哪些实验以及原因。
- 为保持匿名性，作者在投稿时应发布匿名化版本（如适用）。
- 建议在补充材料（附于论文之后）中提供尽可能多的信息，但允许包含数据和代码的URL。

6. **实验设置/细节**

问题：论文是否详细说明了理解结果所需的所有训练和测试细节（例如数据划分、超参数、选择方法、优化器类型等）？

回答：[是]

理由：这些细节已在第5节和补充材料中提供。指南：

- 答案“NA”表示论文中未包含实验内容。
- 实验设置应置于论文的核心部分，其详细程度应足以让读者理解并解读研究结果。
- 完整的细节可通过代码、附录或补充材料的形式提供。

7. **实验的统计学显著性**

问题：论文是否恰当且正确地报告了误差条，或提供了关于实验统计显著性的其他适当信息？

回答：[是]

理由：我们实验结果中的标准差（图3、图4和表1）显示了统计学显著性。

指南：

- 答案“NA”表示该论文未包含实验内容。
- 如果结果附有误差条、置信区间或统计显著性检验（至少针对支持论文主要论点的实验），作者应回答“是”。
- 误差条所反映的变异因素应明确说明（例如，训练/测试集划分、初始化、某些参数的随机抽取，或在给定实验条件下的整体运行）。

- 应说明误差条的计算方法（闭式公式、调用库函数、自举法等）。
- 应说明所做的假设（例如，误差服从正态分布）。
- 应明确说明误差条代表的是标准差还是均值的标准误。
- 报告1-sigma误差条是可以的，但应予以说明。如果误差的正态性假设未得到验证，作者最好报告2-sigma误差条，而不是声称其具有96%置信区间。
- 对于非对称分布，作者应谨慎避免在表格或图中显示对称误差条，以免导致结果超出范围（例如负误差率）。
- 若在表格或图表中报告误差条，作者应在正文中说明其计算方法，并在正文中引用相应的图或表。

8. **实验计算资源**

   问题：对于每项实验，论文是否提供了足够的信息，说明重现实验所需的计算机资源（计算节点的类型、内存、执行时间）？

   回答：[是]

   理由：关于计算机资源的信息已在补充材料中提供。

   指南：

   - 答案“NA”表示论文中未包含实验。
   - 论文应说明计算节点的类型（CPU或GPU）、内部集群或云服务提供商，并包括相关的内存和存储信息。
   - 论文应提供每次单独实验运行所需的计算量，并估算总计算量。
   - 论文应说明整个研究项目是否需要比文中报告的实验更多的计算量（例如，未被纳入论文的初步实验或失败实验）。

9. **道德准则**

   问题：本文所进行的研究在各个方面是否都符合NeurIPS道德准则 `https://neurips.cc/public/EthicsGuidelines`?

   回答：[是]

   理由：我们的研究符合NeurIPS道德准则。指南：

   - 答案“NA”表示作者未审阅NeurIPS伦理准则。
   - 若作者回答“否”，应说明导致偏离《道德准则》的特殊情况。
   - 作者应确保匿名性（例如，如果其所在司法管辖区的法律法规有特殊规定）。

10. **更广泛的影响**

    问题：本文是否同时讨论了所开展工作可能产生的积极社会影响和消极社会影响?

    回答：[不适用]

    理由：本文主要聚焦于如何在基于策略的强化学习中应用扩散模型的理论研究，未涉及社会影响。

    指南：

    - 答案“NA”表示该研究工作不存在社会影响。
    - 若作者回答“NA”或“否”，应说明其研究为何不产生社会影响，或论文为何未涉及社会影响。

- 负面社会影响的示例包括潜在的恶意或非预期用途（例如：虚假信息、生成虚假个人资料、监控）、公平性考量（例如：部署可能做出对特定群体产生不公平影响决策的技术）、隐私考量以及安全考量。
- 本次会议预计将收到许多基础性研究论文，这些论文不会与特定应用相关，更不用说实际部署了。然而，如果存在通向任何负面应用的直接途径，作者应予以指出。 例如，指出生成式模型质量的提升可能被用于生成用于散布虚假信息的深度伪造（deepfakes），这是合理的。另一方面，则无需指出用于优化神经网络的通用算法可能使人们能够更快地训练生成深度伪造的模型。
- 作者应考虑以下三类潜在危害：技术按预期使用且运行正常时可能产生的危害；技术按预期使用但产生错误结果时可能产生的危害；以及因（有意或无意）滥用技术而导致的危害。
- 如果存在负面社会影响，作者还可以探讨可能的缓解策略（例如：分阶段发布模型、在提供攻击手段的同时提供防御措施、监控滥用的机制、监控系统随时间推移如何从反馈中学习的机制，以及提高机器学习的效率和可及性）。

11. **保障措施**

问题：论文是否描述了为负责任地发布存在高滥用风险的数据或模型（例如预训练语言模型、图像生成器或爬取数据集）而采取的保障措施?

回答：[不适用]

理由：本论文的实验是在IsaacLab的8个机器人控制任务上进行的，不存在此类风险。

指南：

- 答案“NA”表示该论文不存在此类风险。
- 对于存在较高滥用或两用风险的已发布模型，应在发布时采取必要的保障措施，以确保对模型的使用受到管控，例如要求用户遵守使用指南或访问模型的限制，或实施安全过滤机制。
- 从互联网抓取的数据集可能存在安全风险。作者应说明如何避免发布不安全的图像。
- 我们认识到提供有效的保障措施具有挑战性，且许多论文并未对此提出要求，但我们鼓励作者将此纳入考量并尽最大努力。

12. **现有资源的许可**

问题：论文中使用的资产（例如代码、数据、模型）的创作者或原始所有者是否已获得适当署名？其许可协议和使用条款是否已明确提及并得到妥善遵守?

回答：[是]

理由：SAC、TD3、DDPG、PPO、DACER、QVPO以及IsaacLab模拟器的实现均已在补充材料中正确引用。

指南：

- 答案“NA”表示该论文未使用现有资产。
- 作者应引用生成该代码包或数据集的原始论文。
- 作者应说明所使用的资源版本，并在可能的情况下提供URL。
- 应为每项资源注明许可协议名称（例如 CC-BY 4.0）。
- 对于从特定来源（如网站）抓取的数据，应提供该来源的版权信息及服务条款。

- 若资产已发布，应提供包中的许可、版权信息及使用条款。对于流行数据集，paperswithcode.com/datasets 已为部分数据集整理了许可信息。其许可指南可帮助确定数据集的许可类型。
- 对于重新打包的现有数据集，应同时提供原始许可和衍生资产的许可（如果已发生变更）。
- 如果这些信息无法在线获取，建议作者联系该资产的创建者。

13. **新资产**

问题：论文中引入的新资产是否已得到充分说明，且相关文档是否随资产一并提供?

回答：[不适用]

说明：本文未引入新资产。指南：

- 答案"NA"表示论文未发布新资产。
- 研究人员应通过结构化模板，在投稿中说明数据集/代码/模型的详细信息。这包括训练、许可、限制等细节。
- 论文应说明是否已从资产提供者处获得同意，以及如何获得同意。
- 提交时，请记得对您的素材进行匿名处理（如适用）。您可以创建一个匿名化的网址，或提供一个经过匿名处理的压缩文件。

14. **众包及涉及人类受试者的研究**

问题：对于众包实验及涉及人类受试者的研究，论文是否包含提供给参与者的完整说明文本及（如有）屏幕截图，以及关于报酬（如有）的详细信息?

回答：[不适用]

理由：该论文不涉及众包或涉及人类受试者的研究。指南：

- 答案"NA"表示该论文不涉及众包或涉及人类受试者的研究。
- 将这些信息纳入补充材料是可以的，但如果论文的主要贡献涉及人类受试者，则应尽可能在正文中详细说明。
- 根据NeurIPS《道德准则》，参与数据收集、整理或其他工作的劳动者，其报酬应至少达到数据收集者所在国家的最低工资标准。

15. **涉及人类受试者的研究应获得机构审查委员会 (IRB) 批准或同等批准**

问题：论文是否描述了研究参与者可能面临的潜在风险，是否向受试者披露了这些风险，以及是否获得了机构审查委员会（IRB）的批准（或根据您所在国家或机构的要求获得的等效批准/审查）?

回答：[不适用]

理由：该论文不涉及众包或涉及人类受试者的研究。指南：

- 答案"NA"表示该论文不涉及众包或涉及人类受试者的研究。
- 根据研究所在国家/地区的要求，任何涉及人类受试者的研究可能都需要获得机构审查委员会（IRB）的批准（或同等批准）。如果您已获得IRB批准，应在论文中明确说明这一点。

- 我们认识到，不同机构和地区的相关程序可能存在显著差异，因此我们期望作者遵守NeurIPS《伦理准则》及其所在机构的指导方针。
- 初次投稿时，请勿包含任何可能破坏匿名性的信息（如适用），例如负责评审的机构名称。

16. **大语言模型（LLM）使用声明**

问题：如果大型语言模型（LLM）是本研究核心方法中重要、原创或非标准的部分，论文是否应说明其使用情况？请注意，如果大型语言模型仅用于写作、编辑或排版，且不影响研究的核心方法、科学严谨性或原创性，则无需进行声明。

回答：[不适用]

理由：我们仅将大语言模型用于论文编辑。指南：

- 答案“NA”表示本研究的核心方法开发中，LLM并未作为任何重要、原创或非标准组件被采用。
- 关于应描述或不应描述的内容，请参阅我们的LLM政策（https://neurips.cc/Conferences/2025/LLM）。